Boyuttan Bağımsız V2G Şarj Kontrolü için Olurluluğu Koruyan Güvenlik Katmanına Sahip Dikkat Tabanlı Güvenli Pekiştirmeli Öğrenme

Yazar Ad(lar)ı*
[YAPILACAK: Kurum(lar), şehir, ülke]

[YAPILACAK: Nihai başlığı yazar belirler; bu, çalışma başlığıdır.]

Bu belge yazarın incelemesi için hazırlanmış Türkçe çeviridir; gönderim sürümü İngilizcedir. Şekillerin içindeki metinler İngilizce bırakılmıştır.

Öz

Araçtan şebekeye (V2G) hizmetleri sunan şarj noktası işletmecileri, istasyonu trafo limiti içinde tutmak ve her sürücüye üzerinde anlaşılan enerjiyi ayrılış anına kadar teslim etmek zorundadır. Pekiştirmeli öğrenme (RL) tabanlı denetleyiciler bu iki gereksinimi genellikle ödüldeki cezalar olarak ele alır ve bu denetleyicilerin ağları tek bir istasyon boyutuna bağlıdır. Bu makale, boyuttan bağımsız dikkat tabanlı bir politikayı bir güvenlik katmanıyla birleştirmektedir; bu katman, araç başına güç sınırları ile iki yönlü trafo limitinin oluşturduğu kümeye kesin bir izdüşümdür (projeksiyon) ve N şarj ünitesi için $O(N \log N)$ sürede hesaplanır. Her şarj ünitesi bir belirteç (token) olarak temsil edildiğinden tek bir ağırlık kümesi, herhangi sayıda şarj ünitesine hizmet edebilir.

Her elektrikli aracın (EV) alt sınırı, ardından tam güçle şarj edildiğinde kabul edilen gereksinimine hâlâ ulaşılabilen en küçük güçtür ve şarj gücü azalmasını (taper) içerir. Kabul edilen bu gereksinim, sürücünün talebinin erişilebilir ve kabul edilebilir olanla sınırlandırılmış hâlidir.

Eğitim ve kullanım sırasında herhangi bir ham eylem dizisi için makale iki sonuç ispatlamaktadır. Simülatöre ve şebeke kapasite payına ilişkin koşullar altında trafo limiti her adımda sağlanır. Buna ek olarak, kalış süresi boyunca olursuz adımla karşılaşmayan her EV, kabul edilen gereksinimini karşılar; burada bir adım, trafo her EV'ye alt sınırını veremiyorsa olursuz sayılır. Geriye kalan adımları en az esneklik payı önce (LLF) ilkesine dayanan bir yedek kural ele alır.

Önceden bildirilmeyen ayrılışlar için ayrılış zamanına ilişkin bölünmüş konformal (split-conformal) bir sınır, ikinci sonucu marjinal kapsamayla genişletir; bu kapsama, nominal düzey ile alt sınırından daha az güç alan EV'lerin oranı arasındaki farktan küçük değildir. Güvenli dikkat tabanlı denetleyici (SA-Attn), EV2Gym simülatöründe 10 ve 20 şarj üniteli istasyonlarda yakınsal politika optimizasyonu (PPO) ile eğitilmekte ve yeniden eğitim olmadan 200 şarj ünitesine kadar test edilmektedir. Denetleyici; öğrenen, kısıtlı RL, sezgisel ve model öngörülü karşılaştırma yöntemleriyle, cezalı kârın tam bilgili optimuma olan açığı ve olursuz adımla karşılaşmayan EV'lerin payı üzerinden karşılaştırılmaktadır. [SONUÇ: ana bulguları içeren bir veya iki cümle: $N = 200$ için cezalı kâr açığı, kalış süresi boyunca olursuz adımla karşılaşmayan EV'lerin oranı, garantinin maliyeti]

Anahtar Kelimeler: Araçtan şebekeye, Elektrikli araç şarjı, Güvenli pekiştirmeli öğrenme, Güvenlik katmanı, Sıfır-atış aktarım

1 Giriş

Bir şarj noktası işletmecisi (CPO), şarj üniteleri için enerjiyi zamanla değişen fiyatlardan satın alır; araçtan şebekeye (V2G) deşarj ise aynı işletmecinin, fiyatlar yüksekken park hâlindeki elektrikli araçlardan (EV) enerji satmasına olanak tanır. İki katı gereksinim bu serbestliği sınırlar. İstasyonun toplam gücü

*Sorumlu yazar: [YAPILACAK: her yazarın adı, e-posta adresi ve ORCID kimliği]

trafo limiti içinde kalmalı ve her EV, ayrılırken üzerinde anlaşılan enerjiye sahip olmalıdır. Aksi hâlde işletmeci ya ekipmanı aşırı yükler ya da sürücüye verdiği hizmet taahhüdünü yerine getiremez.

Fiyatlar, varışlar ve ayrılışlar belirsiz olduğundan ve önceden modellenmeleri güç olduğundan pekiştirmeli öğrenme (RL), bu kontrol görevi için yaygın bir yaklaşım hâline gelmiştir [1, 2]. EV şarjına yönelik RL denetleyicilerinin çoğu, ayrılış enerji gereksinimini ödülde ağırlıklı bir ceza olarak kodlar [3–6]. Trafo limitini modelleyenler de aşırı yüklemeyi genellikle aynı şekilde cezalandırır [6, 7]. Ceza, ihlalleri kârla takas ettiğinden eğitilmiş bir politika test sırasında her iki gereksinimi de ihlal edebilir [6, 8]. Kısıtlı formülasyonlar ise bunun yerine beklenen birikimli maliyeti sınırlar [9]; ancak böyle bir sınır her adımda değil, epizotlar (episode) üzerinden ortalama olarak geçerlidir [10].

İkinci bir sınırlılık istasyon boyutuyla ilgilidir: EV2Gym simülatörünün varsayılan arayüzünde [6] olduğu gibi şarj ünitesi başına bir eylem içeren düz bir gözlem, eğitilmiş bir ağı tek bir şarj ünitesi sayısına bağlar. Çizge ve dikkat tabanlı politikalar bu kısıtlamayı ortadan kaldırır [7, 11, 12]; ne var ki boyuttan bağımsız bu denetleyicilerde kısıtlar hâlâ ödül terimleri, taklit verisi ya da sezgisel filtreler aracılığıyla devreye girer.

Güvenlik katmanları her eylemi uygulanmadan önce düzeltir ve limitleri yapıları gereği sağlayabilir [8, 13, 14]. EV istasyonları için mevcut katmanlar ya trafo kapasitesi ve şarj ünitesi akımı gibi adım başına limitleri kapsar [15] ya da güvenli olmayan eylemleri başka eylemlerle değiştirir [16, 17]. Yalnızca adım başına çalışan bir katman, ayrılış enerji gereksinimini korumaz; çünkü bu gereksinim, o anki eylemi kalış süresinin sonraki her adımıyla ilişkilendirir. Araç başına en geç başlangıç sınırları bu bağlantıyı esneklik payına (laxity) dayalı çizelgelemede [18] ve yakın tarihli hiyerarşik bir V2G çizelgeleyicisinde [19] ele almaktadır. Bölüm 2.5, bu unsurların birleşimini en yakın çalışmalarla karşılaştırarak konumlandırmaktadır.

Bu makale, bir CPO istasyonunda V2G şarj kontrolü için güvenli dikkat tabanlı bir denetleyici (SA-Attn) önermektedir. Dikkat tabanlı politika her şarj ünitesini bir belirteç olarak ele alır ve ortak ağırlıklarla belirteç başına bir ham güç eylemi üretir. Olurlu kümeye kesin bir izdüşüm (projeksiyon) olan güvenlik katmanı, ham eylemleri araç başına sınırlara ve trafo limitine uyan komut güçlerine dönüştürür. Bir kutunun iki yönlü bir toplam kısıtıyla kesişimine izdüşüm klasik bir problemdir [20, 21]; yumuşatılmış en az esneklik payı önce (sLLF) çizelgelemesinin hız kuralı da buna çok yakın bir biçime sahiptir [18]. Olurluluk argümanımız, Chen ve arkadaşlarının esneklik payı argümanını şarj gücü azalmasına (taper), V2G deşarjına ve iki yönlü bir bağlantıya genişletmektedir.

Makalenin dört katkısı vardır.

1. Araç başına alt sınırı şarj gücü azalmasını içeren bir güvenlik katmanı türetilmekte ve Teorem 1 bu katmanın sonucunu iki katmanda ifade etmektedir. Simülatöre ve şebeke kapasite payına ilişkin koşullar altında trafo limiti, her ham eylem dizisi için her adımda sağlanır; kabul edilen ayrılış gereksinimi ise kalış süresi boyunca olursuz adımla karşılaşmayan her EV tarafından karşılanır.
2. Katmanın boyuttan bağımsız taşıyıcısı olarak şarj ünitesi belirteçlerine dayalı bir dikkat tabanlı politika kullanılmakta ve bu politika, katman eğitim döngüsünün içindeyken eğitilmektedir. Ayrılış sınırı içermeyen, katmanı yalnızca kullanım aşamasında uygulayan ve Deep Sets politikası kullanan varyantlar her bir parçanın katkısını göstermektedir.
3. Denetleyici, EV2Gym'de 10 ve 20 şarj ünitesiyle eğitilerek ve 200 şarj ünitesine kadar boyutlarda ve daha sıkı bir trafo anma değerinde sıfır-atış (yeniden eğitim olmadan) testlerle değerlendirilmektedir. Ana ölçüt, karşılaştırılan her yöntemi üstten sınırlayan tam bilgili bir optimuma göre cezalı kâr açığıdır. Birincil sonlanım noktalarından biri olursuz adımla karşılaşmayan EV'lerin payıdır; katı kısıtlı bir optimum ise garantinin maliyeti analizini desteklemektedir.
4. İkincil bir katkı olarak, ayrılış adımına ilişkin bölünmüş konformal bir alt sınır, ayrılışın bilindiği varsayımının yerini almakta ve Önerme 2 ayrılış sonucunu bir kapsama ifadesine dönüştürmektedir.

Bu bileşenlerin hiçbiri tek başına yeni değildir; dolayısıyla makalenin iddiası bunların birleşimine, iki katmanlı sonuca ve bu sonucun ölçülen maliyetine dayanmaktadır.

Bölüm 2 ilgili çalışmaları gözden geçirmekte, Bölüm 3 modeli kısmen gözlemlenebilir bir Markov karar süreci (POMDP) olarak ifade etmekte ve Bölüm 4 yöntemi sunmaktadır. Bölüm 5–8 sırasıyla deney düzeneğini, bulguları, tartışmayı ve sonucu kapsamakta; tüm ispatlar ve ek ayrıntılar ise ek materyalde yer almaktadır.

2 İlgili Çalışmalar

2.1 EV şarjı ve V2G için pekiştirmeli öğrenme

EV şarjına yönelik derin RL çalışmaları tek araçlı ajanlardan [22] fotovoltaik, depolama ve V2G içeren istasyonlara [5, 17], koordineli istasyonlara [23] ve dağıtım şebekesi limitleri altındaki filolara [24, 25] doğru ilerlemiştir. İki derleme çalışması; güvenliği, simülasyona bağımlılığı ve standart bir kıyaslama ortamının eksikliğini açık problemler arasında saymaktadır [1, 2]. EV2Gym, şarj üniteleri esnek olmayan yük ve güneş üretimi bulunan trafoların arkasında yer alan bir CPO'yu modellemektedir [6]. EV2Gym'in V2G ödülü trafo aşırı yüklemesini ve düşük kullanıcı memnuniyetini cezalandırır; V2G kıyaslamasında cezaya dayalı ajanlar kâr elde etmiş, ancak birçok kullanıcıyı talep ettikleri enerjinin altında bırakmıştır. Adaptive Charging Network (ACN), katı altyapı limitleri ve en iyi çaba esaslı enerji teslimiyle kayan ufukta bir dışbükey program çözmektedir [26]. EV2Gym içindeki ekonomik bir model öngörülü kontrol (MPC) yöntemi, ayrılış ve trafo kısıtlarını katı olarak uygulamaktadır [27].

2.2 Kısıt yönetimi ve güvenli pekiştirmeli öğrenme

Ödüldeki ağırlıklı ihlal terimleri test sırasında ihlalleri önlemez [6,8]. Kısıtlı Markov karar süreci (CMDP) bunun yerine beklenen birikimli bir maliyeti sınırlar [9] ve Lagrange [28] ya da güven bölgesi [29] güncellemeleriyle çözülür. Derleme çalışmaları, bu tür sınırların her adımda değil beklenen birikimli bir maliyet için geçerli olduğunu belirtmekte [10] ve Lagrange yöntemlerini yumuşak garantiler olarak sınıflandırmaktadır [30]. CMDP formülasyonları gerilim limitleri [31], trafo ısıl zorlanması [32, 33] ve V2G toplayıcıları [34] ile EV şarjına uygulanmıştır. Lagrange tabanlı çok ajanlı bir yöntem ayrıca her istasyonun yakın geçmişini bir Transformer ile kodlamaktadır [35].

İkinci bir yöntem ailesi her eylemi uygulanmadan önce kalkanlar (shield) [36], öğrenilmiş doğrusal güvenlik katmanları [13] ya da yedek denetleyicili kuadratik programlar [37] aracılığıyla düzeltir. EV alanındaki örnekler arasında kural tabanlı kalkanlar [16], eylem değiştirme katmanları [17], şebeke yönetmeliğine dayalı kalkanlama [38] ve güç akışı kalkanları [39] bulunmaktadır. Böyle bir filtre ancak iç modeli kadar güvenlidir; HetGPS ön baskısının yazarları da doğrusallaştırılmış bir güç akışı izdüşümüyle birlikte kullanılan öğrenilmiş risk modeli için noktasal bir olurluluk iddiasında bulunmamaktadır [12]. EV2Gym ekibinin üyeleri ayrıca çizge ile güçlendirilmiş bir ikiz gecikmeli derin deterministik politika gradyanı (TD3) ajanını [40] bir güvenlik katmanıyla birleştirmiştir [41]. Bölüm özetine göre bu katmanın amacı şarj gereksinimlerini korumak ve güç limitlerini uygulamaktır.

Üçüncü bir aile, politikanın çıktısını yapısı gereği olurlu kılar. Türevlenebilir dışbükey optimizasyon katmanları gradyanları kesin bir çözümden geçirir [42, 43]; Chen ve arkadaşları da böyle bir izdüşümü enerji sistemi politikalarının içinde kullanmıştır [14]. Gauge eşlemeleri doğrudan olurlu noktalar verir [44]; Tabas ve Zhang, öğrenilmiş bir frekans denetleyicisinin kontrollü değişmez bir güvenli kümede kaldığını ispatlamak için bu eşlemelerden birini kullanmıştır [8]. EV istasyonları için Wan ve arkadaşlarının bir ön baskısı, trafo ve şarj ünitesi akımı limitlerini kapsayan ancak ayrılış enerjisini kapsamayan bir kuadratik program izdüşümünün adım başına olurluluğunu ispatlamaktadır [15]. Yan ve arkadaşlarının bir ön baskısı araç başına sınırları kalan enerji ve süreden türetmektedir; bu çalışmanın biçimsel sonucu birinci dereceden güç dengesi olurluluğuyla ilgilidir [19]. İzdüşüm öğrenmeyi de etkiler; çünkü naif izdüşüm politika gradyanlarını yanlı hâle getirir [45] ve aktif bir izdüşümün gradyanları sıfırdır [46]. Stokastik politikalar için yakın tarihli bir ön baskı, ortamın içindeki izdüşümün bir politika katmanı olarak izdüşüme denk olduğunu göstermektedir [47].

2.3 Boyuttan bağımsız mimariler

Deep Sets [48], öz-dikkat [49] ve Set Transformer [50], ortak ağırlıklarla her boyuttaki kümeleri işleyebilir; UPDeT bu fikri farklı boyutlardaki çok ajanlı görevlere uygulamıştır [51]. Boyut aktarımı kendiliğinden gerçekleşmez; küçük çizgeler üzerinde eğitilen sinirsel rotalama çözücüleri daha büyük çizgelerde sıklıkla başarısız olur [52]. EV şarjında boyuttan bağımsız ilk durum gösterimleri toplulaştırmadan elde edilmiş; Sadeghianpourhamami ve arkadaşları ayrıca ölçeklenmiş varış hızları altında mükemmel bilgiye sahip bir optimuma olan açığı raporlamıştır [3]. Ancak toplulaştırılmış gösterimler araç başına ayrıntıyı gizler ya da bu ayrıntıyı ayrıştırma kurallarına taşır [53, 54].

Heterojen çizge politikasının (EV-GNN) ön baskı sürümü, her ölçek için ayrı bir model kullanarak ve yapısı gereği hiçbir kısıtı uygulamadan 1000'e kadar şarj noktasını koordine etmektedir [11]. Buna karşılık, 25 şarj ünitesinde eğitilen çizge ile güçlendirilmiş karar Transformer'ı (GNN-DT), yeniden eğitim olmadan 5 ile 100 arasında şarj ünitesinde test edilmiş ve boyut büyüdükçe performansı düşmüştür [7]. 1236 araçla eğitilen bir HetGPS politikası, yeniden eğitim olmadan 2239 ve 3218 araçlı fiderlere aktarılabilmektedir [12]. Benzer şekilde, gerilim kontrolüne yönelik çizge tabanlı bir aktör, simülasyonda eğitimdekinden daha büyük bir fider üzerinde değerlendirilmiştir [55].

Boyuttan bağımsız bu denetleyicilerde kısıtlar ödül terimleri, taklit verisi ya da sezgisel filtreler aracılığıyla devreye girer.

2.4 Esneklik payına dayalı çizelgeleme ve ayrılış belirsizliği

Chen ve arkadaşları, bir çizelgenin ancak ve ancak her esneklik payı, yani kalan süre ile şarjı tamamlamak için hâlâ gereken süre arasındaki fark, negatif olmadığında olurlu olduğunu ispatlamıştır [18]. Onların sLLF kuralı, istasyon güç limiti altında her hızı ortak bir düzey etrafında kırpar; ortaya koydukları sınırlar ise çevrim içi olurluluğun genellikle ek güç gerektirdiğine işaret etmektedir. Bir ön baskı, katı son tarihlerin ve bir trafo limitinin tıkanıklık altında birlikte olursuz hâle gelebileceğini göstermektedir [56]; en az esneklik payı önce (LLF) öncelikleri ise kablo ve trafo limitleri altında iyi performans göstermektedir [57, 58]. Bu yöntemler, kullanıcıların ayrılış zamanını ve enerjiyi varışta bildirdiğini varsayar. Bağlı kalma süreleri zor tahmin edilir [59], kullanıcılar son tarihlerini olduğundan erken bildirerek kazanç sağlayabilir [60] ve ayrılış tahminleri önceliklendirmeyi iyileştirir [61]. Yakın tarihli bir ön baskı, bir ayrılış tahmincisini şarj politikasıyla uçtan uca eğitmekte, ancak karşılanmayan enerjiyi yumuşak bir ceza olarak tutmakta ve herhangi bir kapsama ifadesi sunmamaktadır [62]. Konformal tahmin, değiştirilebilirlik (exchangeability) altında dağılımdan bağımsız kapsama sağlar [63, 64] ve güvenli planlamada kısıtları sıkılaştırmak için kullanılmıştır [65].

2.5 Konumlandırma

Tablo 1 incelendiğinde görüldüğü gibi, tasarımımızın her bileşeni bir biçimde zaten mevcuttur. EV şarjı için sıfır-atış aktarıma sahip boyuttan bağımsız politikalar [7, 12], güvenli RL'de ispatlanabilir eylem düzeltme katmanları [8, 15] bulunmaktadır; ortak bir düzey etrafında kırpmaya dayanan çok yakın bir kural da sLLF'de yer almaktadır [18]. Araç başına en geç başlangıç sınırları Yan ve arkadaşlarının çizelgeleyicisinde [19] görülmekte; küçükte eğitip büyükte test etmeye ve bir optimuma olan açığa dayalı değerlendirme ise en azından [3] çalışmasına kadar uzanmaktadır. Yakın tarihli ve konuyla çok yakından ilişkili üç çalışmaya yalnızca özetleri üzerinden erişilebilmiştir [23, 34, 41]; bu çalışmalar yalnızca bu düzeyde aktarılmaktadır. Bildiğimiz kadarıyla, boyuttan bağımsız öğrenilmiş bir politikayı, adım başına bir trafo garantisini ve çok adımlı bir ayrılış argümanını tek bir denetleyicide birleştiren önceki bir çalışma bulunmamaktadır.

3 Problem Formülasyonu

3.1 İstasyon, EV'ler ve enerji dinamiği

Bir CPO, tek bir trafonun arkasında N şarj ünitesine $\mathcal{N} = \{1, \dots, N\}$ sahip bir istasyon işletir; her şarj ünitesine en fazla bir EV bağlanır ve bu EV'ye ait büyüklükler şarj ünitesinin i indisini taşır. Zaman, Δt [h] uzunluğundaki $t = 0, \dots, T-1$ adımlarına bölünmüştür. İstasyon her adımda trafo anma gücünü $P_{\mathrm{tr}}(t)$, esnek olmayan yükü $P^{\mathrm{inf}}(t) \geq 0$ ve fotovoltaik (PV) üretimi $P^{\mathrm{pv}}(t) \geq 0$ kW cinsinden gözlemler. Enerji $c^{\mathrm{ch}}(t)$ fiyatından satın alınır ve $c^{\mathrm{dis}}(t)$ [€/kWh] fiyatından satılır; her iki fiyat da negatif olabilir.

EV i, t_i^{arr} adımında varır ve son kontrol edilen adım olan ayrılış adımı d_i'ye kadar kontrol edilir; dolayısıyla ayrılış enerjisi $E_i(d_i + 1)$'dir; burada $E_i(t)$, t adımının başındaki batarya enerjisidir. t adımında EV'nin $\tau_i(t) = d_i - t + 1$ kalan eylemi vardır ve $\mathcal{N}(t)$, $n(t)$ adet dolu şarj ünitesinin kümesidir. $p_i(t)$ [kW], i şarj ünitesine komut edilen güç olsun; bu güç şarj için pozitif, V2G deşarjı için negatiftir. $\tilde{p}_i(t)$ ise simülatörün raporladığı güç olsun. $p^+ = \max(p, 0)$ ve $p^- = \max(-p, 0)$ olmak üzere batarya enerjisi

$$E_i(t+1) = E_i(t) + \Delta t \, g_i\big(p_i(t)\big), \qquad g_i(p) = \eta_i^{\mathrm{c}} p^+ - p^- / \eta_i^{\mathrm{d}}, \tag{1}$$

Tablo 1: En yakın çalışmalara göre konumlandırma. "Ceza" bir ödül terimini; "katı" ise yapısı gereği uygulanan bir kısıtı ifade eder.

Çalışma	Boyuttan bağımsız politika	Ayrılış enerjisi	Trafo limiti	Garanti	Sıfır-atış boyut testi	Optimuma olan açık
EV2Gym ajanları [6]	hayır (düz)	ceza	ceza	yok	hayır	karşılaştırma yöntemi olarak optimum
EV-GNN, ön baskı sürümü [11]	evet (çizge)	yapısı gereği değil	yapısı gereği değil	yok	her ölçek için ayrı model	her ölçek için optimizasyon tabanlı karşılaştırma
GNN-DT [7]	evet (çizge)	ceza	ceza	yok	25'ten 5–100 şarj ünitesine	kâhin (oracle) düzeyine yakın ödül (dergi özeti)
HetGPS, ön baskı [12]	evet (çizge dikkati)	ödül ve sezgisel yöntem	kısıtlanmamış	deneysel (gerilim filtresi)	1236'dan 3218 araca	hayır
Yan vd., ön baskı [19]	hayır	katı (araç başına kural)	modellenmemiş	birinci dereceden güç dengesi	hayır	MPC'ye göre açık
Wan vd., ön baskı [15]	hayır	modellenmemiş	katı (kuadratik program izdüşümü)	adım başına olurluluk	hayır	hayır
sLLF [18]	kural, her boyut	esneklik payı kuralı	katı (ortak düzey)	olurluluk teoremleri	öğrenilmemiş	hayır
Sadeghian-pourhamami vd. [3]	evet (toplu durum)	ceza	modellenmemiş	yok	ölçeklenmiş varışlar	evet
Orfanoudakis vd. [41] (özet)	çizge politikası	güvenlik katmanı (belirtilen amaç)	güvenlik katmanı (belirtilen amaç)	özette belirtilmemiş	özette belirtilmemiş	özette belirtilmemiş
Bu çalışma	evet (şarj ünitesi belirteçleri)	araç başına sınır, koşullu (Teo. 1b)	katı (ortak kaydırma)	trafo: her adımda (A3, A6); ayrılış: araç başına, koşullu	10/20'den 200 şarj ünitesine	yumuşak ve katı kısıtlı optimumlar

biçiminde değişir; burada $\eta_i^{\mathrm{c}}, \eta_i^{\mathrm{d}} \in (0,1]$ şarj ve deşarj verimleridir. Adım başına fiziksel limitler gücü

$$p_i^{\min}(E) \le p_i(t) \le \bar{P}_i(E), \qquad p_i^{\min}(E) = -\min\left\{P_i^{\mathrm{dis}},\ \eta_i^{\mathrm{d}}\frac{(E-E_i^{\min})^+}{\Delta t}\right\}, \qquad E = E_i(t), \tag{2}$$

aralığıyla sınırlar; burada en yüksek şarj gücü $\bar{P}_i(E) \ge 0$ şarj gücü azalmasını ve kapasite limitini içerir, $\bar{P}_i^{\mathrm{nom}} = \sup_E \bar{P}_i(E)$'dir ve P_i^{dis} en yüksek deşarj gücüdür. Kuram genel g_i eşlemesi için geçerlidir; ancak EV2Gym, batarya tarafındaki enerji değişimini şarj ünitesi gücü olarak raporlar, faturalandırır ve ölçer [6]. Bu nedenle deneylerimizde $\eta_i^{\mathrm{c}} = \eta_i^{\mathrm{d}} = 1$ alınmaktadır; bu kabul, V2G arbitrajındaki gidiş-dönüş kaybını ortadan kaldırmaktadır (Bölüm 7.3).

3.2 Ayrılış gereksinimi ve trafo limiti

Her EV, istenen bir ayrılış enerjisi E_i^{des} talep eder ve istasyon düzeyindeki bir talep işleme hattı bu talebi kabul edilen gereksinim E_i^{req}'ye dönüştürür. İşleme hattı, her test tekrarı (replay) için herhangi bir denetleyiciden önce bir kez çalışır; karşılaştırılan her yöntem ve her iki optimum aynı kabul edilen gereksinimi alır. Varışta talep, kalış süresi boyunca tam güçte şarjın ulaşabileceği enerjiyle, bu değerin yaklaşık 10^{-6} kWh altında olacak şekilde sınırlandırılır. Ardından kabul kontrolü küçük bir olurluluk doğrusal programı (LP) çözer ve bağlı EV'lerin tümüne öngörülen trafo limitleri altında hizmet verilemeyecekse yeni talebi düşürür. Daha önce kabul edilmiş talepler hiçbir zaman azaltılmaz. Dolayısıyla

$$E_i^{\mathrm{req}} \le \min\left\{E_i^{\mathrm{des}},\ \text{kalış süresince } E_i^{\mathrm{arr}} \text{ değerinden tam güçle erişilebilen enerji}\right\} \tag{3}$$

olur; ayrıntılar Bölüm S3 içinde verilmektedir. Ayrılış gereksinimi şudur:

$$E_i(d_i+1) \ \ge \ E_i^{\mathrm{req}}. \tag{4}$$

Bu sınırlama olmasaydı bazı varışlara hiçbir denetleyici hizmet veremezdi ve bunlara ilişkin bir garanti anlamsız olurdu. Her yöntem için eksik enerji, ortak kabul edilen gereksinime göre ölçülür; işleme hattının çıkardığı enerji ise ayrıca raporlanır.

Net trafo gücü $P^{\mathrm{inf}}(t) - P^{\mathrm{pv}}(t) + \sum_i p_i(t)$, $[-P_{\mathrm{tr}}(t), P_{\mathrm{tr}}(t)]$ aralığında kalmalıdır; dolayısıyla EV toplamı için trafo limiti

$$-C_{\mathrm{rev}}(t) \le \sum_{i \in \mathcal{N}} p_i(t) \le C(t), \qquad C(t) = P_{\mathrm{tr}}(t) - P^{\mathrm{inf}}(t) + P^{\mathrm{pv}}(t), \qquad C_{\mathrm{rev}}(t) = P_{\mathrm{tr}}(t) + P^{\mathrm{inf}}(t) - P^{\mathrm{pv}}(t) \tag{5}$$

biçimindedir. İleri yön limiti $C(t)$ şarjı, ters yön limiti $C_{\mathrm{rev}}(t)$ ise V2G ile dışarı verilen gücü sınırlar. Güvenlik katmanı mevcut adım için ölçülen yük ve PV değerlerini kullanırken politika gelecekteki değerlerin yalnızca gürültülü tahminlerini gözlemler.

3.3 Çevrim içi kontrol problemi ve optimumlar

CPO her adımda $p(t) \in \mathbb{R}^N$ değerini yalnızca t adımında mevcut olan bilgiyi kullanarak seçer. Bir π denetleyicisinin bir epizottaki € cinsinden kârı

$$J^{\pi} = \sum_{t=0}^{T-1} \Delta t \sum_{i \in \mathcal{N}(t)} \left(c^{\mathrm{dis}}(t)\, \tilde{p}_i^{-}(t) - c^{\mathrm{ch}}(t)\, \tilde{p}_i^{+}(t) \right) \tag{6}$$

olarak tanımlanır ve denetleyici bunun beklenen değerini Denklem 1–2, her EV için Denklem 4 ve her adımda Denklem 5 kısıtları altında en büyüklemelidir. Her yöntem için $w_E = w_P = 10\,€/\mathrm{kWh}$ ağırlıklarıyla cezalı kâr

$$J^{\mathrm{pen}}(\pi) = J^{\pi} - w_E \sum_i \Delta E_i^{\mathrm{sh}} - w_P\, \Delta t \sum_t \left[\Big(\sum_i \tilde{p}_i(t) - C(t) \Big)^{+} + \Big(-C_{\mathrm{rev}}(t) - \sum_i \tilde{p}_i(t) \Big)^{+} \right] \tag{7}$$

olarak tanımlanır; burada $\Delta E_i^{\mathrm{sh}} = (E_i^{\mathrm{req}} - E_i(d_i + 1))^{+}$ ayrılıştaki eksik enerjidir.

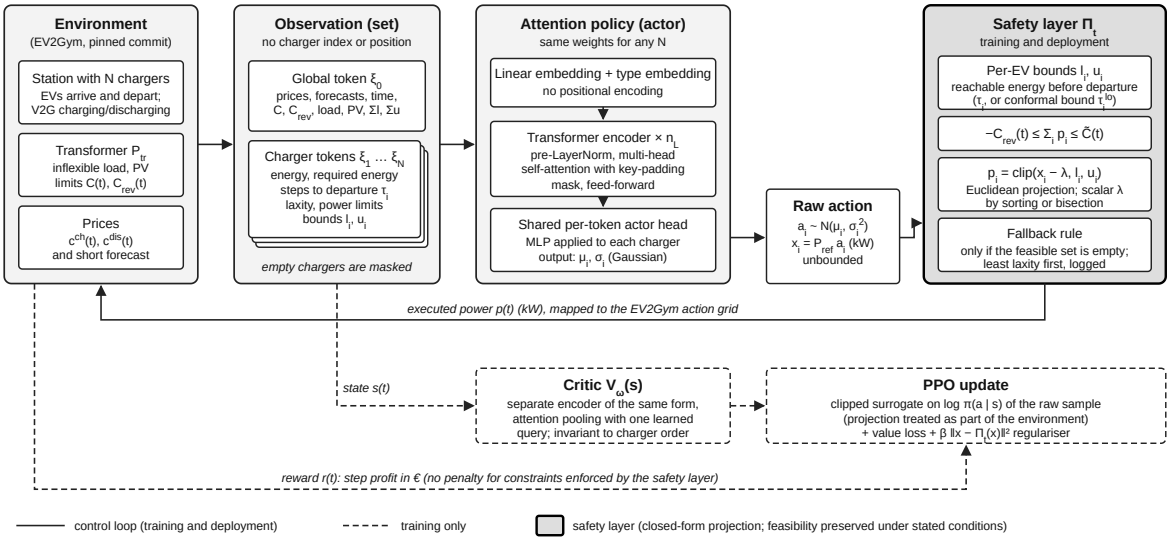
HiGHS [66] ile çözülen iki tam bilgili LP, epizodun tamamını bilir ve referans olarak kullanılır. Her ikisi de EV2Gym'in şarj gücü azalmasını dış doğrusal kısıt satırlarıyla modeller; bu satırlar tek adımlık bir geçiş bandı ve %1'lik bir pay dışında kesindir (Lemma S8); ayrıca her ikisi de EV2Gym'in faturalandırılmayan 0.01 kWh'lik yuvarlama kazancını hesaba katar. Yumuşak cezalı optimum $J^{\mathrm{pen,LP}}$, eksik enerji ve aşırı yük için gevşek değişkenlerle Denklem 7 ifadesini en büyükler. Eksik enerji ortak kabul edilen gereksinime göre ölçüldüğünde, eksik enerji ya da aşırı yük içeren yörüngeler de dâhil olmak üzere simüle edilen her yörünge için $J^{\mathrm{pen}}(\pi) \le J^{\mathrm{pen,LP}}$ sağlanır (Önerme S3). Dolayısıyla ana ölçüt, karşılaştırılan her yöntem için iyi tanımlıdır:

$$\mathrm{gap}^{\mathrm{pen}}(\pi) = \frac{J^{\mathrm{pen,LP}} - J^{\mathrm{pen}}(\pi)}{|J^{\mathrm{pen,LP}}|} \ge 0; \tag{8}$$

burada mutlak değer gereklidir, çünkü kârlar genellikle negatiftir. $|J^{\mathrm{pen,LP}}| < 1\,€$ olan ya da çözücü durumu optimal olmayan epizotlar için açık hesaplanmaz ve bunların sayısı raporlanır. Katı optimum $J^{\mathrm{LP,ceil}}$, toplam eksik enerjiyi en küçükleyen ilk aşamadan sonra ayrılış gereksinimlerini ve trafo limitini kısıt olarak uygular. Bu optimum, trafo limitine uyan ve daha fazla eksik enerji bırakmayan her denetleyicinin kârını üstten sınırlar (Önerme S2) ve garantinin maliyeti analizinde kullanılır.

3.4 Kısmen gözlemlenebilir Markov karar süreci

Gelecekteki varışlar, kısa bir pencerenin ötesindeki fiyatlar ve gelecekteki yükler gözlemlenmediğinden çevrim içi problem bir POMDP'dir. Mevcut gözlem üzerinden ileri beslemeli bir aktör ve kritik ile eylem seçilmektedir. Politika her şarj ünitesi için bir ham eylem $a_i(t) \in \mathbb{R}$ üretir; bu eylem $P^{\mathrm{ref}} = 11$ kW olmak üzere $x_i(t) = P^{\mathrm{ref}} a_i(t)$ biçiminde kW'a ölçeklenir ve Bölüm 4.3 içindeki güvenlik katmanı onu herhangi bir sıkıştırma fonksiyonu kullanmadan komut edilen güce eşler. Politikanın ödülü adımın gerçekleşen kârıdır; ayrılış gereksinimi ya da trafo limiti için ceza içermez, çünkü güvenlik katmanı her ikisini de uygular. Eğitimde ödül, getirilerin N ile büyümemesi için $r^{\mathrm{ref}} = c^{\mathrm{ref}} P^{\mathrm{ref}} \Delta t$ ve $c^{\mathrm{ref}} = 0.25\,€/\mathrm{kWh}$ olmak üzere $N r^{\mathrm{ref}}$'ye bölünür; raporlanan tüm sonuçlar ise bölünmemiş kârı kullanır. Varışlar, fiyatlar, yükler ve PV eylemlerden bağımsız olarak değişir, her EV epizot bitmeden ayrılır ve indirim faktörü $\gamma = 0.99$, $\Delta t = 15$ dk için yaklaşık bir günlük etkin ufuk sağlar.



Şekil 1: SA-Attn yönteminin mimarisi ve kontrol döngüsü. Düz oklar eğitimde ve kullanımda işletilen kontrol döngüsünü oluşturur; kesikli oklar yalnızca eğitimde kullanılır. Güvenlik katmanı (gölgeli), trafo limitini koruyan ve her EV alt sınırını aldığı sürece EV'nin gereksinimini erişilebilir tutan kesin bir izdüşümdür (Teorem 1).

4 Önerilen Yöntem

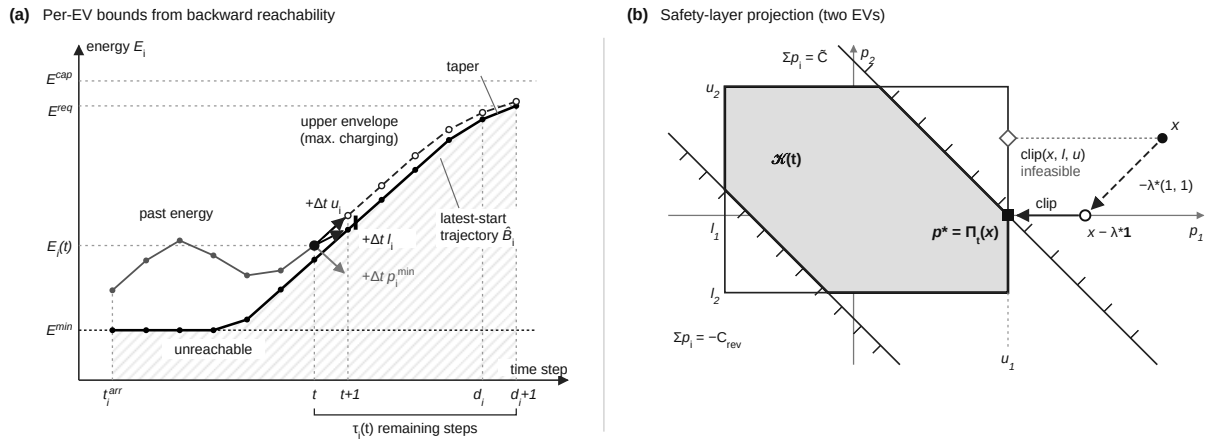
Şekil 1 üzerinde görüldüğü gibi SA-Attn, her adımda art arda çalışan üç parçadan oluşur. Dikkat tabanlı politika, bir şarj ünitesi belirteçleri kümesini şarj ünitesi başına bir ham eyleme eşler; güvenlik katmanı ise ham eylemleri araç başına sınırlara ve trafo limitine uyan komut güçlerine dönüştürür. Eğitim sırasında bir politika gradyanı yöntemi, güvenlik katmanını ortamın bir parçası olarak ele alarak politikayı gerçekleşen kâra göre günceller; aynı katman kullanım sırasında da değişmeden çalışır.

4.1 Belirteç gösterimi ve dikkat tabanlı politika

Gözlem, N adet şarj ünitesi belirteci $\xi_i(t) \in \mathbb{R}^{12}$ ve bir küresel belirteç $\xi_0(t) \in \mathbb{R}^{38}$ içeren bir kümedir; hiçbir öznitelik bir şarj ünitesinin indisini ya da konumunu kodlamaz. Bir şarj ünitesi belirteci doluluk, enerji ve kapasite verilerini, kalan gerekli enerjiyi ve adım sayısını, Bölüm 4.2 içinde tanımlanan esneklik payını, güç limitlerini ve l_i ile u_i sınırlarını içerir. Küresel belirteç sonraki $H_f = 8$ adımın fiyatlarını, zaman özniteliklerini, mevcut limitleri, yük ve PV tahminlerini ve dört istasyon oranını içerir. Tüm öznitelikler N ile büyümeyecek biçimde normalize edilir; Tablo S3 bunları listelemektedir.

Her belirteç, öğrenilen iki tür gömmesinden biriyle birlikte doğrusal olarak gömülür: şarj üniteleri için $e_i = W_c\xi_i + b_c + v_c$, küresel belirteç için $e_0 = W_g\xi_0 + b_g + v_g$. $[e_0; e_1; \ldots; e_N]$ dizisi, genişliği $d_m = 128$ olan, $n_H = 4$ başlıklı ve konum kodlaması içermeyen $n_L = 3$ adet ön-LayerNorm'lu Transformer kodlayıcı katmanından geçer [49,67,68]. Bir anahtar dolgu maskesi boş şarj ünitelerini dikkat anahtarları arasından çıkarır; küresel anahtar ise hiçbir zaman maskelenmez. Ardından ortak bir aktör başlığı, her şarj ünitesi çıktısı h_i'yi Gauss dağılımlı bir ham eylemin $\mu_{\theta,i}$ ortalamasına ve $\sigma_{\theta,i}$ standart sapmasına eşler; burada θ aktör parametrelerini gösterir. Politika $\pi_\theta(a \mid s) = \prod_{i\in\mathcal{N}(t)} \mathrm{Normal}\big(a_i; \mu_{\theta,i}(s), \sigma^2_{\theta,i}(s)\big)$ biçimindedir. ω parametreli ayrı bir kritik kodlayıcısı, maskelenmemiş tüm belirteç çıktılarını öğrenilen tek bir dikkat sorgusuyla [50] havuzlayarak $V_\omega(s)$ değerini üretir.

Bu yapı permütasyona eşdeğişkendir (permutation-equivariant); maskelenmiş belirteçler maskelenmemiş belirteçlerin çıktılarını etkilemez ve parametre sayısı N'ye bağlı değildir (Lemma S1). Şarj ünitesi sayısı ne olursa olsun aktörün 610 370, kritiğin ise 676 481 parametresi vardır. Dolayısıyla $N \in \{10, 20\}$ ile eğitilen ağırlıklar $N = 200$ için çalıştırılabilir; ancak bu boyutta performans garanti edilmez, çünkü 200 belirteç üzerindeki dikkat, eğitimde görülenden daha fazla anahtar üzerinden ortalama alır.



Şekil 2: Güvenlik katmanının kavramları. (a) Bir EV'nin kalış süresi boyunca enerjisi; en geç başlangıç yörüngesi $\hat{B}_i$ ve adım başına $\Delta t\, u_i$, $\Delta t\, l_i$ ve $\Delta t\, p_i^{\min}$ seçenekleriyle birlikte. (b) İki EV için $-C_{\text{rev}} \le p_1 + p_2 \le \tilde{C}$ dilimiyle kesilen $[l, u]$ kutusuna izdüşüm.

4.2 Erişilebilir enerjiden türetilen araç başına sınırlar

Güvenlik katmanı, bağlı her EV için ayrılış gereksinimini erişilebilir tutan en küçük güce ihtiyaç duyar; karışıklığa yol açmadığı yerlerde i indisi yazılmamaktadır. Bir adım boyunca tam güçte şarj, E enerjisini $\varphi(E) = E + \Delta t\, \eta^{\mathrm{c}}\, \bar{P}(E)$ değerine eşler. Bölüm 4.4 içindeki A1 varsayımı, φ'nin sürekli ve azalmayan olmasını, yani bir adıma daha fazla enerjiyle başlamanın tam güçte şarjdan sonra hiçbir zaman daha az enerji bırakmamasını gerektirir. Gereksinime tam güçte hâlâ erişilebilen en küçük enerjiler olan geriye doğru erişilebilirlik eşikleri şunlardır:

$$B(0) = E^{\mathrm{req}}, \qquad B(k) = \min\big\{E \in [E^{\min}, E^{\mathrm{cap}}] :\ \varphi(E) \ge B(k-1)\big\}, \quad k \ge 1. \tag{9}$$

A1 altında bir EV, t adımında bireysel olarak olurludur (yani kabul edilebilir bir kontrol Denklem 4 koşulunu sağlar) ancak ve ancak $E(t) \ge B(\tau(t))$ ise (Lemma S2). A1 olmadan bu nitelendirme geçerliliğini yitirir, çünkü şimdi daha az şarj etmek daha sonra daha fazla erişilebilir enerji bırakabilir. EV2Gym'in üstel şarj gücü azalması için Lemma S6, A1'i her adım uzunluğu için ispatlamaktadır.

$E = E_i(t)$ enerjisine ve $\tau = \tau_i(t)$ kalan eyleme sahip bağlı bir EV için güvenlik katmanının sınırları şunlardır:

$$u_i(t) = \bar{P}(E), \qquad l_i(t) = \begin{cases} \min\Big\{u_i(t),\ \max\Big\{p^{\min}(E),\ g^{-1}\Big(\dfrac{\hat{B}(\tau-1) - E}{\Delta t}\Big)\Big\}\Big\}, & E \ge \hat{B}(\tau), \\ \bar{P}(E), & E < \hat{B}(\tau), \end{cases} \tag{10}$$

burada $\hat{B}$ saklanan bir eşik tablosu, dıştaki minimum ise sayısal bir korumadır. Birinci durumda l_i, ardından gelen $\tau - 1$ tam güç adımının E^{req} değerine hâlâ ulaştığı kabul edilebilir en küçük güçtür; bireysel olarak olursuz bir EV ise en yüksek güçte şarj edilir. Negatif bir alt sınır, pay kaldığı sürece V2G deşarjına izin verir ve Şekil 2(a) üzerinde görüldüğü gibi sınır, enerjiyi en geç başlangıç yörüngesinin üzerinde ya da bu yörünge üzerinde tutar.

$\hat{B}_i(k)$, $k = 0, \ldots, \tau_i(t_i^{\mathrm{arr}})$ tablosu varışta φ_i üzerinde ikiye bölme (bisection) yöntemiyle bir kez hesaplanır; böylece sınırların maliyeti EV ve adım başına $O(1)$ olur. Saklanan her tablo

$$\hat{B}(0) \ge E^{\mathrm{req}}, \qquad \varphi\big(\hat{B}(k)\big) \ge \hat{B}(k-1), \qquad \hat{B}(k) \le \max\{\hat{B}(k-1), E^{\min}\}, \qquad \hat{B}(k) \in [E^{\min}, E^{\mathrm{cap}}] \tag{11}$$

anlamında sertifikalıdır ve ispatlar yalnızca bu özellikleri kullanır. Adım cinsinden ölçülen esneklik payı $\chi_i(t) = \big(E_i(t) - \hat{B}_i(\tau_i(t))\big)/\big(\eta_i^{\mathrm{c}} \bar{P}_i^{\mathrm{nom}} \Delta t\big)$, ancak ve ancak EV bireysel olarak olurlu olduğunda negatif değildir.

4.3 İzdüşüm

$x \in \mathbb{R}^N$, kW cinsinden ham eylem olsun; boş şarj üniteleri için $x_i = l_i = u_i = 0$ alınır. Güvenlik katmanı, sıkılaştırılmış ileri yön limiti olan $\tilde{C}(t) = C(t) - n(t)\varepsilon_q$ ifadesini kullanır; burada şarj ünitesi

başına $\varepsilon_q = 0.008$ kW'lık pay, simülatörün eyleyici yuvarlamasını karşılar (Bölüm S2.2). Olurlu küme $\mathcal{K}(t) = \{p \in \mathbb{R}^N : \; l \le p \le u, \; -C_{\mathrm{rev}}(t) \le \mathbf{1}^\top p \le \tilde{C}(t)\}$ olup güvenlik katmanı şu Öklid izdüşümüdür:

$$\Pi_t(x) = \arg\min_{p \in \mathcal{K}(t)} \tfrac{1}{2}\|p - x\|_2^2. \tag{12}$$

Önerme 1 (İzdüşüm)**.** *(i) $\mathcal{K}(t)$ kümesi ancak ve ancak $l \le u$, $\sum_i l_i \le \tilde{C}$, $\sum_i u_i \ge -C_{\mathrm{rev}}$ ve $-C_{\mathrm{rev}} \le \tilde{C}$ ise boş değildir.*

(ii) $\mathcal{K}(t) \neq \emptyset$ ise Denklem 12 probleminin tek minimize edicisi $p_i^* = \mathrm{clip}(x_i - \lambda^*, l_i, u_i)$'dir. Kırpılmış nokta toplam limiti zaten sağlıyorsa ortak kaydırma λ^* sıfırdır; aksi hâlde λ^*, $\lambda \mapsto \sum_i \mathrm{clip}(x_i - \lambda, l_i, u_i)$ fonksiyonunun ihlal edilen limitteki köküdür.

İspat Karush–Kuhn–Tucker (KKT) koşullarını doğrulamaktadır; ek materyal ayrıca Jacobi matrisini de vermektedir (Önerme S1). Şekil 2(b) üzerinde görüldüğü gibi izdüşüm, tüm serbest koordinatları aynı miktarda kaydırır ve toplam limit sağlanana kadar kırpar. $2N$ kırılma noktasının $\{x_i - u_i\} \cup \{x_i - l_i\}$ bir kez sıralanması ve bunlar üzerinden bir kez geçilmesi λ^* değerini verir; dolayısıyla katmanın maliyeti adım başına $O(N \log N)$'dir. İkiye bölme yöntemine dayalı yedekli bir son denetim, kayan nokta yuvarlamasına karşın toplam limiti korur; Algoritma S1 tam bir adımı listelemektedir.

Bu cebir yeni değildir: Denklem 12 sürekli kuadratik sırt çantası problemidir [20, 21]; sLLF hız kuralı da buna çok yakın bir biçim, yani her EV için tepe hızıyla ölçeklenen ortak bir düzey kullanır [18]. Bizim kullanımımız iki bakımdan farklıdır: girdi, boyuttan bağımsız bir politikanın öğrenilmiş şarj ünitesi başına eylemidir; l_i alt sınırı ise şarj gücü azalmasını ve V2G işaret aralığını içeren geriye doğru erişilebilirlikten türetilir. Ayrıca toplam kısıtı iki yönlüdür ve katman eğitim sırasında da çalışır.

4.4 Olurluluğun korunması

Sezgisel olarak güvenlik katmanı, hiçbir EV'nin gereksinimine tam güçte hâlâ erişilebilen en küçük enerjinin altına düşmesine izin vermez; ortak kaydırma ise istasyonu trafo bandı içinde tutar. Bu özelliklerden yalnızca ilki sağlanamayabilir; bu durum, trafo her EV'ye alt sınırını aynı anda veremediğinde ortaya çıkar. $\mathcal{K}(t)$ boş olmadığında bir adımı olurlu olarak adlandırıyoruz; olursuz bir adımda izdüşümün yerini bir yedek kural alır. Sonucun koşulları aşağıda toplanmıştır ve bunlardan yalnızca ilk beşi varsayımdır. Teknik açıdan, sonucun dayandığı tümevarım Chen ve arkadaşlarının esneklik payı argümanını [18] şarj gücü azalmasına, V2G deşarjına, iki yönlü bir bağlantıya ve keyfî ham eylemlere genişletmektedir.

Teorem 1'in koşulları

Etiket	Koşul	Bu çalışmadaki durumu
A1	φ sürekli ve azalmayan	EV2Gym'in şarj gücü azalması için ispatlanmıştır (Lemma S6)
A2	ayrılış adımı d_i ve gereksinim E_i^{req} varışta biliniyor	konformal sınır ile gevşetilmiştir (Bölüm 4.6)
A3	tek adım modeli: Denklem 2 içindeki komutlar için $E_i(t+1) \ge E_i(t) + \Delta t\, g_i(p_i)$ ve $p_i \le \tilde{p}_i \le p_i + \varepsilon_q$	EV2Gym'in eyleyici davranışı için ispatlanmıştır (Lemma S7); donanımda sağlanamayabilir
A4	olurlu varış: $E_i^{\mathrm{arr}} \ge \hat{B}_i(\tau_i(t_i^{\mathrm{arr}}))$	talep işleme hattı tarafından uygulanır
A6	şebeke kapasite payı: $C(t) \ge N\varepsilon_q$ ve $C_{\mathrm{rev}}(t) \ge 0$	dışsaldır; yedek kural sayımlarıyla denetlenir
A5	olurlu adım: $\sum_i l_i \le \tilde{C}$, $\sum_i u_i \ge -C_{\mathrm{rev}}$, $\tilde{C} \ge -C_{\mathrm{rev}}$	kapalı döngüde ortaya çıkan bir olaydır; (a) ve (b) tarafından varsayılmaz; ölçülür

A6, politikaya bağlı olmaması için $n(t)$ yerine şarj ünitesi sayısı N'yi kullanır ve senaryolarımızda epizot başına 2×10^{-9}'un altında bir olasılıkla sağlanamaz (Bölüm S2.3).

Teorem 1 (Olurluluğun korunması)**.** *Eğitim ya da kullanım sırasında, sonlu ham eylemlerden oluşan keyfî bir dizi için komut edilen güçler olurlu adımlarda $p(t) = \Pi_t(x(t))$, diğer adımlarda ise yedek kuralın çıktısı olsun.*

(a) A3 ve A6 altında, her adımda gerçekleşen güçler $-C_{\mathrm{rev}}(t) \le \sum_i \tilde{p}_i(t) \le C(t)$ trafo limitini, komut edilen güçler ise Denklem 2 ile verilen fiziksel limitleri sağlar.

(b) A1–A4 altında, kalış süresi boyunca $p_i(t) \geq l_i(t)$ olan her EV i, $E_i(d_i+1) \geq E_i^{\mathrm{req}}$ koşulunu sağlar; özellikle kalış süresi boyunca olursuz adımla karşılaşmayan her EV bu koşulu sağlar.

(c) Ek olarak her adım olurlu ise her EV ayrılış gereksinimini karşılar.

İspat taslağı. Olurlu adımlarda Önerme 1(i) $p(t) \in \mathcal{K}(t)$ sonucunu verir ve A3, sıkılaştırılmış bandı gerçekleşen güçlere aktarır. A6 altında yedek kural yalnızca aşağıda açıklanan gerekli güç fazlası durumuyla karşılaşabilir ve bu durumda çıktısı, komut edilen toplamı $\tilde{C}(t)$ değerinde tutar. (b) için tek adımlık bir lemma (Lemma S3), $E_i(t) \geq \hat{B}_i(\tau_i(t))$ değişmezini A4'ün sağladığı varıştan itibaren $p_i \geq l_i$ olan her adım boyunca taşır; son adımda bu değişmez $E_i(d_i+1) \geq \hat{B}_i(0) \geq E_i^{\mathrm{req}}$ sonucunu verir. (c) şıkkı (b)'den çıkar; tam ispat Bölüm S1.5 içinde verilmektedir. □

Trafoya ilişkin kısım ne politikaya ne de A1 ya da A5'e bağlıdır; ayrılışa ilişkin kısım ise araç başına bir ifadedir. A5, ortak bir plan mevcut olduğunda bile sağlanamayabilir. 10 kW'lık bir limit altında her biri 1 saatlik iki adım içinde 10 kWh'e ihtiyaç duyan iki EV, kapasiteyi eşit biçimde paylaşabilir. Ancak birinci adımda boşta bekleyen bir politika, ikinci adımda $\sum_i l_i = 20$ kW bırakır. Bu nedenle EV'lerin olursuz adımlarla ne sıklıkta karşılaştığı ölçülmektedir.

4.5 Yedek kural

Olursuz bir adımda yedek kural, izdüşümün yerine en az esneklik payı önce ilkesine dayanan deterministik bir paylaştırma koyar. İlgili durumda gerekli güç $\sum_i l_i$, $\tilde{C}$ değerini aşar. Bu durumda her EV fiziksel alt limiti $p_i^{\min}$'den başlar ve $\tilde{C}$ değerine kadar kalan bütçe, esneklik payı artan sırada EV'lere, her biri en fazla l_i'ye kadar olmak üzere dağıtılır. Bu çıktı trafo limitini korur ve hâlâ l_i alan her olurlu EV olurlu kalır (Lemma S4). Üç ek durum çelişkili limitleri, aşırı PV ihracatını ve negatif bir bütçeyi kapsar; A6 bu üçünü de dışlar (Bölüm S1.6). l_i'den daha az alan EV'ler için bir epizottaki toplam ayrılış eksikliği, bu adımlarda biriken açık ile önsel olarak sınırlanır (Lemma S5). Talep işleme hattındaki kabul kontrolü olursuz adımları daha seyrek hâle getirir; ancak tahminlere dayanır ve Teorem 1 kapsamına girmez.

4.6 Ayrılış adımı için konformal alt sınır

Ayrılış adımı açısından A2'yi gevşetmek için tek yönlü, kantil regresyonu biçiminde [69] bölünmüş konformal tahmin (CP) [63, 64, 70, 71] kullanılmaktadır. Bir gradyan artırma (gradient boosting) regresörü $\hat{q}$, d_i'nin alt kantilini varış adımından, haftanın gününden, varış enerjisinden, talep edilen enerjiden ve EV modelinden kestirir. Kalibrasyon, bağımsız tohumlarla (seed) üretilmiş n_{cal} epizodun her birinden düzgün dağılımla bir oturum seçer ve $e_j = \hat{q}(\mathbf{w}_j) - d_j$ skorlarını kullanır. $\hat{Q}_{1-\alpha}$, $\lceil (n_{\mathrm{cal}}+1)(1-\alpha) \rceil$'inci en küçük skor olmak üzere $\hat{d}_i^{\mathrm{lo}} = \max\{t_i^{\mathrm{arr}}, \lceil \hat{q}(\mathbf{w}_i) - \hat{Q}_{1-\alpha} \rceil\}$ sınırı; sınırlarda, talep işleme hattında ve özniteliklerde d_i'nin yerini alır ve $\hat{d}_i^{\mathrm{lo}}$ adımından sonra katman tek bir kalan adım kullanır.

Önerme 2 (Konformal ayrılış garantisi)**.** *Kalibrasyon oturumları ile test oturumu değiştirilebilir (exchangeable) olsun. Bu durumda $\mathbb{P}(d_i \geq \hat{d}_i^{\mathrm{lo}}) \geq 1-\alpha$ olur ve d_i yerine $\hat{d}_i^{\mathrm{lo}}$ alınarak A1, A3 ve A4 altında $\mathbb{P}\big(E_i(d_i+1) \geq E_i^{\mathrm{req}}\big) \geq 1 - \alpha - \mathbb{P}\big(\exists\, t \leq d_i :\ p_i(t) < l_i(t)\big)$ sağlanır.*

Burada E_i^{req}, $\hat{d}_i^{\mathrm{lo}}$ ile yeniden sertifikalanmış gereksinimdir ve olasılık, kalibrasyon verisi ile bir test epizodundan düzgün dağılımla seçilen bir EV üzerinden alınır; dolayısıyla garanti marjinaldir. Kalibrasyon her test yapılandırmasından veri gerektirdiğinden konformal varyant sıfır-atış değildir.

4.7 Eğitim algoritması

Politika, güvenlik katmanı, yedek kural ve eyleyici davranışı ortamın parçası olarak ele alınarak yakınsal politika optimizasyonu (PPO) [72] ve genelleştirilmiş avantaj kestirimi [73] ile eğitilir. Bu nedenle PPO, ham Gauss örneğinin olabilirlik oranını kullanır. Eski parametrelerdeki PPO vekil amaç gradyanına eşit olan temel (vanilla) politika gradyanı kestiricisi, bu durumda izdüşümü alınmış eylemlerin getirisi için yansızdır. Stokastik politikalar için ortamın içindeki ve politikanın içindeki izdüşüm bu anlamda denktir [47]; bu tercih aktif bir izdüşümün sıfır gradyanlarından da kaçınır [46]. $u_i - l_i \leq 10^{-9}$ kW olan belirteçler hiçbir komut gücünü etkileyemeyeceğinden log-olasılıktan ve entropiden çıkarılır. Yedek kural

adımları aktör kaybında maskelenir, ancak kritik için tutulur. Birçok ham eylem aynı izdüşüm noktasına eşlendiğinden olurlu adımlarda $\beta = 0.01$ ağırlıklı bir düzenlileştirici, politika ortalamasını $\mathcal{K}(t)$'ye yakın tutar:

$$\mathcal{L}_{\text{reg}}(\theta) = \beta\, \mathbb{E}_s\Big[\frac{1}{n(t)} \sum_{i \in \mathcal{N}(t)} \Big(\frac{\bar{x}_i - \Pi_t(\bar{x})_i}{P^{\text{ref}}}\Big)^2\Big], \qquad \bar{x} = P^{\text{ref}} \mu_\theta(s). \tag{13}$$

Moreau özdeşliğine göre $\frac{1}{2}\text{dist}^2(x, \mathcal{K})$'nin gradyanı $x - \Pi_t(x)$'tir; bu nedenle $\Pi_t(\bar{x})$ gradyan durdurma (stop-gradient) altında hesaplanır [14, 47]. Her veri toplama turu (rollout) $N = 10$ olan sekiz ve $N = 20$ olan sekiz ortam çalıştırır; tam eğitim döngüsü Algoritma S2 içinde verilmektedir.

5 Deney Düzeneği

5.1 Simülatör ve senaryolar

Tüm deneylerde, kaynak kodunda değişiklik yapılmadan `55ef368c` commit'indeki EV2Gym [6] kullanılmaktadır. Bir sarmalayıcı (wrapper) gözlemleri hesaplar; ortak kabul edilen gereksinimleri, güvenlik katmanını, yedek kuralı ve eyleyici davranışını uygular ve gelecekteki varışları okumadan tüm ölçütleri kaydeder. Her istasyonda tek bir trafonun arkasında N şarj ünitesi bulunur; EV'ler simülatörün V2G destekli sekiz EV modelinden, her model için sabit bir verimle (bir model için 0.93, diğerleri için 0.90) çekilir. İstenen enerji bataryanın tam dolu hâlidir; fiyatlar EV2Gym ile birlikte sunulan Hollanda gün öncesi fiyatlarıdır ve deşarj fiyatı şarj fiyatına eşittir. Tablo S2 tüm senaryo parametrelerini listelemektedir.

Şebeke büyüklükleri ve varış hızı N ile doğrusal olarak ölçeklenir. Özellikle trafo anma gücü $P_{\text{tr}} = \rho_{\text{tr}} N$'dir; burada EV2Gym'in 25 şarj üniteli V2G yapılandırmasındaki gibi şarj ünitesi başına $\rho_{\text{tr}} = 4$ kW'lık sıkı bir düzey ve 7 kW'lık orta bir düzey kullanılır. Esnek olmayan yük ve PV, ortalaması $0.4P_{\text{tr}}$ olan çarpanlarla ölçeklenir ve gözlemdeki tahminler standart sapması %10 olan Gauss gürültüsü içerir. EV2Gym'in işyeri, kamusal ve özel varış profilleri, gece boyu süren oturumların 15 dakikalık $T = 112$ adımdan oluşan 28 saatlik ufka sığmasını sağlayan saatlerde başlar. Ortalama şarj ünitesi doluluğu her profil için yaklaşık 0.21'dir.

Eğitim, her yığında (batch) $N \in \{10, 20\}$ değerlerini, üç profili ve iki anma düzeyini karıştırır. Test ızgarası $N \in \{5, 10, 20, 50, 100, 200\}$ değerlerini, her iki anma düzeyini ve tüm profilleri; buna ek olarak $N \in \{20, 200\}$ için $\rho_{\text{tr}} = 3$ kW'lık bir stres düzeyini kapsar. Dolayısıyla sıfır-atış ifadesi istasyon boyutunu ve stres düzeyini ifade eder; profiller ise eğitimde görülmüştür. Her yapılandırma, tüm yöntemlerce paylaşılan ve $N \leq 50$ için 100, $N \geq 100$ için 50 sabit test epizoduna sahiptir; EV2Gym'in özgün 25 şarj üniteli yapılandırması 100 epizot daha ekler; böylece her politika 3550 test epizodunda çalıştırılır. Şarj ünitesi başına büyüklükler N ile değişmediğinden toplam dalgalanmalar N büyüdükçe küçülür; toplam limitlerin ne sıklıkta bağlayıcı olduğu her N için raporlanmaktadır. $N = 20$ ve $\rho_{\text{tr}} = 4$ kW için yapılan duyarlılık çalışmaları, 0.8'lik istenen şarj durumunu, 5 dakikalık adımı, 0.05 €/kWh'lik enerji akışı (throughput) maliyetini ve 0.9'luk deşarj fiyatı çarpanını kapsar. Yalnızca 5 dakikalık çalışmada yeniden eğitim yapılır.

5.2 Karşılaştırılan yöntemler

Her yöntem ve her değerlendirme geçişi aynı kabul edilen gereksinimleri alır ve eksik enerji her zaman bu gereksinimlere göre ölçülür. Katman içermeyen yöntemler, l_i ya da trafo bağlantısı olmaksızın yalnızca fiziksel kırpma $\text{clip}(x_i, p_i^{\min}, u_i)$ işlemini uygular; her yöntem ayrıca çıktısı güvenlik katmanından geçirilerek de çalıştırılabilir.

Öğrenen yöntemler mümkün olduğunca dikkat kodlayıcısını paylaşır. Attention+penalty, SA-Attn yönteminin cezaya dayalı ikizidir: güvenlik katmanı olmaksızın, kârdan eksik enerji ve aşırı yük enerjisinin w ağırlığıyla çarpımı çıkarılarak elde edilen değerden öğrenir. Bunun kısıtlı karşılığı olan Attention+PPO-Lagrangian, sabit ağırlığın yerine maliyet limiti sıfır olan Lagrange çarpanlarını kullanır [9, 28]. $l_i = p_i^{\min}$ alındığında "Attention+safety layer without departure bound" (ayrılış sınırı olmayan dikkat+güvenlik katmanı) varyantı, katmanı [15] çalışmasındaki gibi adım başına bir trafo izdüşümüne indirger, $\beta = 0.01$ değerini korur ve ayrılış gereksinimini ceza içeren ödülden öğrenir. Deep Sets+safety layer, dikkat içermeyen, ortalama havuzlanmış bir bağlam kullanan, boyuttan bağımsız ve belirteç başına çalışan bir ağdır; parametre sayısı SA-Attn ile %10 içinde eşleştirilmiştir. Ceza ile eğitilmiş kontrol noktaları ayrıca

güvenlik katmanı yalnızca kullanım aşamasında uygulanarak çalıştırılır; SA-Attn ve Attention+penalty ayrıca kabul kontrolü olmaksızın, varışta sınırlandırılmış talep korunarak çalıştırılır. Sıfırla doldurulmuş belirteçler üzerinde çalışan, katmanlı ve katmansız çok katmanlı algılayıcı (MLP), yalnızca $N \leq 20$ için değerlendirilen sabit boyutlu bir referanstır. Dağılım içi bir referans olarak SA-Attn ayrıca üç tohumla $N = 50$ için eğitilir ve $N \in \{50, 100, 200\}$ için değerlendirilir.

Karşılaştırmayı altı kural tamamlar: olabildiğince hızlı, olabildiğince geç, döngüsel sıralama (round robin), LLF, sLLF [18] ve bir fiyat eşiği kuralı. EV2Gym'in ekonomik MPC'sinin [27] HiGHS ile yaptığımız yeniden gerçeklemesi her N için 10 adımlık bir ufukla (eMPC-HiGHS) ve 24 saatlik bir ufukla (eMPC-HiGHS-24h) çalışır. Her ikisi de ufukları içindeki kesin fiyatları ve varışları bilir, ki bu bir bilgi avantajıdır; Gurobi tabanlı özgün eMPC ise çapraz kontrol amacıyla literatür yapılandırmasında çalıştırılır. EV-GNN [11], `01aa1b7a` commit'indeki açık kaynak kodundan, kendi TD3 eğitim betiği, ödülü ve hiperparametreleriyle; $N = 20$ ve $\rho_{\text{tr}} = 4$ kW için her varış profiline bir model olmak üzere beş tohumla çalıştırılır. Bizim yöntemlerimizden farklı olarak kendi yapılandırmasında, çalıştırma başına tek bir yük ve PV çekilişiyle ve varsayılan 10^7 yerine 3×10^6 adımla eğitilir. Hem bu yapılandırmada hem de sıfır-atış olarak raporlanır. GNN-DT'nin [7] açık kaynak kodu (DT4EVs, commit `8b327d12`) mevcuttur; ancak bu yöntem her senaryo için bir optimizasyon çözücüsünün ürettiği veri kümeleri üzerinde çevrim dışı eğitilmektedir ve bu iş akışının uyarlanması bu çalışmanın kapsamı dışında kalmıştır.

SA-Attn için ablasyonlar $\beta = 0$ alır, müfredatlı (curriculum) eğitim kullanır ya da daha küçük bir ağ kullanır. Attention+penalty ayrıca adım başına yoğun bir açık cezası ile ve $w \in \{1, 100\}$ €/kWh ile (üç tohum) eğitilir. Konformal varyant SA-Attn-CP, $\alpha = 0.1$ için bir kez eğitilir ve her α için yeniden kalibre edilmiş sınırlarla değerlendirilir; ablasyonu olarak kalibre edilmemiş bir nokta tahmini kullanılır.

5.3 Ölçütler

Ana ölçüt, her yöntem için geçerli olan Denklem 8 ile tanımlı cezalı kâr açığıdır; kâr, karşılanmayan enerji ve trafo aşırı yük enerjisi ayrıca raporlanır. Güvenlik katmanı için kalış süresi boyunca olursuz adımla karşılaşmayan EV'lerin payı, yedek kural durumlarına göre olursuz adımlar ve Lemma S5 ile verilen açık sınırıyla karşılaştırmalı olarak ölçülen eksik enerji raporlanır. Garantinin maliyeti, aynı epizotlar üzerinde Attention+penalty ile SA-Attn arasındaki farktır; birincil ölçü olarak J^{pen}, ikincil ölçü olarak kâr kullanılır. Bu maliyet, eşleştirilmiş epizotlar üzerinden toplamların oranıdır ve hizmet verilen EV başına € ile $|J^{\text{LP,ceil}}|$'nin yüzdesi olarak ifade edilir. Pozitif bir değer, cezaya dayalı ikizin daha yüksek puan aldığı anlamına gelir. SA-Attn yönteminin $N = 50$ için eğitilen referansa göre aktarım açığı, aktarım kaybını yöntem kaybından ayırır.

5.4 Ayarlama, istatistik ve hesaplama

Ayarlanan yedi öğrenen yöntemin her biri, öğrenme oranı, mini yığın boyutu ve entropi katsayısı üzerinde tanımlı bir ızgaradan 12 yapılandırma alır. Ceza içeren ödüller ızgaraya $w \in \{1, 10, 100\}$ ağırlığını, Lagrange yöntemi ise çarpan adım büyüklüğünü ekler. Her yapılandırma eğitim karışımı üzerinde 0.5×10^6 adım eğitilir ve test tekrarlarından ayrık 24 doğrulama epizodunda değerlendirilir. Seçim, her yöntem için $w = 10$ ile hesaplanan doğrulama J^{pen} değerini kullanır; böylece cezaya dayalı bir yöntem kendi ağırlığını düşürerek üstünlük elde edemez. Seçilen yapılandırma beş tohumla 3×10^6 adım boyunca yeniden eğitilir; Tablo S4 hiperparametreleri listelemektedir.

Analiz birimi eğitim tohumudur, tohum sayısı önceden sabitlenmiştir ve tekrar düzeyindeki değerlerin ortalaması önce her tohum içinde alınır. Önceden bildirilen birincil sonlanım noktalarımız $N = 200$ için açık (E1), her N için garantinin maliyeti (E2), aşırı yük enerjisi (E3) ve olursuz adımla karşılaşmayan EV'lerin payıdır (E4). Birincil test olarak eşleştirilmiş bir t-testi aynı sabit tekrarlar üzerindeki tohum ortalamalarını karşılaştırır; tohum ortalamalı politikaların tekrar düzeyindeki farkları üzerinde uygulanan Wilcoxon işaretli sıralar testi [74] ise ikincildir. Holm düzeltmesi her sonuç tablosu üzerinde uygulanır; tabakalı bootstrap ile elde edilen %95 güven aralıkları, çeyrekler arası ortalama (IQM) ve iyileşme olasılığı raporlanır [75]. Az sayıda tohuma dayanan sonuçlar yanıltıcı olabilir [76] ve beş tohumla testlerin gücü düşüktür; bu nedenle güven aralıkları birincil kanıttır (Bölüm S4.4).

Gerçekleme PyTorch [77], CleanRL tarzında [78] tek dosyalık bir PPO ve Adam optimize edicisini [79] kullanmakta; güvenlik katmanı çift duyarlıkla çalışmaktadır. Genel olarak temel deneyler eğitim için yaklaşık 32 GPU-saati; değerlendirme, kabul tabloları, kalibrasyon ve optimumlar için ise 82–132 CPU-saati

Tablo 2: Eğitim istasyon boyutları $N \in \{10, 20\}$ için ana karşılaştırma (üç varış profili ve her iki sıkılık düzeyi birleştirilmiştir; analiz betikleri çalıştırılana kadar yer tutucudur).

Yöntem	J^{pen} [€]	Açık [%]	IQM açık [%]	Kâr [€]	Karşılanmayan [kWh]	Aşırı yük [kWh]
SA-Attn (önerilen)	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]
Attention+penalty	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]
Attention+PPO-Lagrangian	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]
Deep Sets+safety layer	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]
Kurallar ve eMPC-HiGHS	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]	[SONUÇ:]

SONUÇ ŞEKLİ YER TUTUCUSU

beklenen dosya: `fig3_zero_shot_scaling.pdf` (analysis/figures/)

Yöntem başına N'ye göre şarj ünitesi başına cezalı kâr ve optimallik açığı, %95 güven aralıkları; eğitim boyutları işaretlenmiştir.

Şekil 3: 5 ile 200 arasındaki N değerleri için istasyon boyutları arasında sıfır-atış aktarım.

gerektirmektedir (Bölüm S4.5). Tüm deneyler yazarlar tarafından kendi donanımlarında yürütülmektedir [YAPILACAK: CPU, GPU, bellek, işletim sistemi, Python ve PyTorch sürümleri]. Kod, yapılandırmalar ve analiz betikleri makaleyle birlikte yayımlanacaktır [YAPILACAK: depo bağlantısı].

6 Bulgular

[YAPILACAK: İskelet: yazarlar aşağıdaki her cümle kalıbını kendi metinleriyle değiştirir, kırmızı yer tutucuları analiz çıktılarından doldurur ve tüm yorumları kendileri yazar].

6.1 Ana karşılaştırma

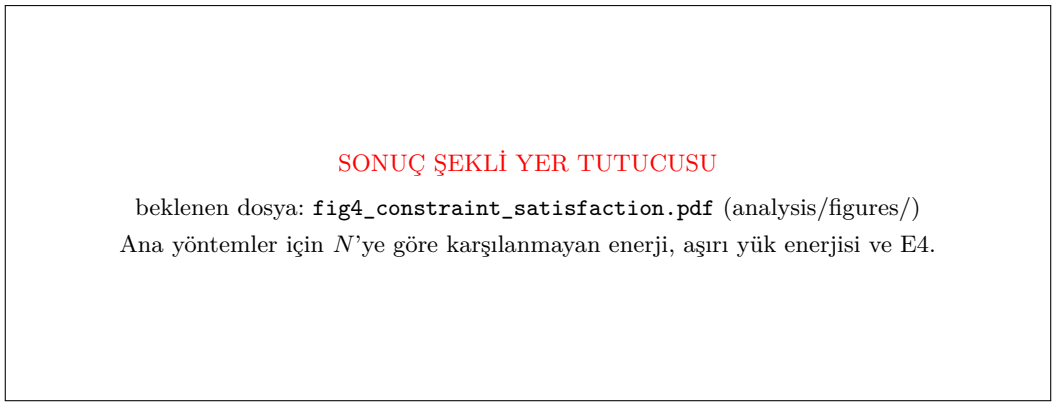
Tablo 2, profiller ve anma düzeyleri birleştirilerek eğitim boyutları $N \in \{10, 20\}$ için tüm yöntemleri karşılaştırmaktadır. Bu boyutlarda SA-Attn yönteminin açığı [SONUÇ: açık ve %95 güven aralığıyla IQM, Tablo 2] olarak bulunmuştur. Diğer öğrenen yöntemlere göre cezalı kârdaki fark [SONUÇ: farklar, güven aralıkları ve Holm düzeltmeli p-değerleri, stats/tests_T1.csv] şeklindedir. Kurallar ve model öngörülü yöntemler arasında [SONUÇ: güvenlik katmanıyla en iyi kural ve eMPC-HiGHS açıkları, Tablo 2].

6.2 İstasyon boyutları arasında sıfır-atış aktarım

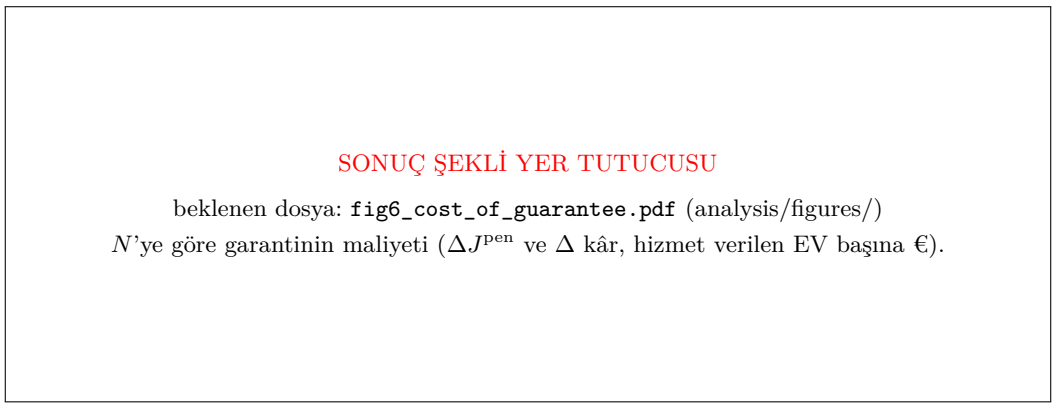
Şekil 3, $N \in \{10, 20\}$ için eğitilmiş ağırlıklarla şarj ünitesi başına cezalı kârı ve açığı N'ye göre çizmektedir. $N = 50$, 100 ve 200 için SA-Attn yönteminin açığı [SONUÇ: %95 güven aralığıyla her N için açık, Tablo S5], $N = 50$ için eğitilen referansa göre aktarım açığı ise [SONUÇ: Tablo S5] olarak bulunmuştur. EV-GNN [SONUÇ: kendi eğitim yapılandırmasında ve sıfır-atış durumunda açık, Tablo S5] değerine ulaşmakta; $\rho_{\text{tr}} = 3$ kW stres düzeyinde SA-Attn yönteminin açığı ise [SONUÇ: Tablo S13] olmaktadır.

6.3 Kısıtların sağlanması

Şekil 4, ana yöntemler için karşılanmayan enerjiyi, aşırı yük enerjisini ve olursuz adımla karşılaşmayan EV'lerin payını (E4) N'ye göre göstermektedir. Güvenlik katmanıyla aşırı yük enerjisi [SONUÇ: Tablo S6



Şekil 4: Kalış süresi boyunca olursuz adımla karşılaşmayan EV'lerin payı (E4) dâhil olmak üzere istasyon boyutları arasında kısıtların sağlanması.



Şekil 5: İstasyon boyutları arasında garantinin maliyeti. Pozitif bir değer, aynı epizotlar üzerinde Attention+penalty'nin SA-Attn yönteminden daha yüksek puan aldığı anlamına gelir.

içindeki değer; Teorem 1(a) sıfır öngörür] olmakta; katman olmadan ise yöntemler [SONUÇ: karşılanmayan enerji ve aşırı yük, Tablo S6] bırakmaktadır. SA-Attn yönteminin E4 değeri [SONUÇ: her N için, Tablo S7] olup toplam limitler [SONUÇ: her N için bağlayıcılık oranları, Tablo S7] oranında bağlayıcı olmaktadır. Olursuz adımlar yedek kural durumlarına [SONUÇ: durum başına sayılar, Tablo S7] biçiminde dağılmakta ve eksik enerji [SONUÇ: açık sınırına oran, Tablo S6] düzeyine ulaşmaktadır.

6.4 Garantinin maliyeti

Şekil 5, Bölüm 5.3 içinde tanımlanan garantinin maliyetini N'ye göre çizmektedir. Cezalı kâr açısından Attention+penalty eksi SA-Attn farkı [SONUÇ: her N için hizmet verilen EV başına € ve $|J^{\text{LP,ceil}}|$'nin %'si olarak ΔJ^{pen}, Tablo S8] olarak bulunmuştur. Ham kâr cinsinden ölçüldüğünde fark [SONUÇ: her N için Δ kâr, Tablo S8] olup testler [SONUÇ: stats/tests_T5.csv] içinde verilmektedir.

6.5 Diğer bulgular

Tablo S9 içinde ayrılış sınırı olmayan, katmanı yalnızca kullanım aşamasında uygulayan ve kabul kontrolü içermeyen varyantlar [SONUÇ: SA-Attn yöntemine göre açıklar, Tablo S9] sonucunu vermektedir. Konformal varyant için açık ve epizot ortalamalı kapsama [SONUÇ: her α için, Tablo S10] olup $N = 200$ için bir kontrol adımı [SONUÇ: çıkarım süresi, Tablo S11] sürmektedir. Duyarlılık çalışmaları [SONUÇ: Tablo S13] sonucunu vermekte; Şekil S7 ise örnek bir epizodu göstermektedir.

7 Tartışma

7.1 Yorum

[YAPILACAK: Paragraf 1, yazarlar tarafından: 10 ve 20 şarj ünitesiyle eğitilen ağırlıkların 200 şarj ünitesine ve stres düzeyine aktarılıp aktarılmadığını belirtin. Şekil 3, Tablo S5 içindeki aktarım açığı ve yedek kural sütunları, Tablo S7 içindeki bağlayıcılık oranları ve Tablo S13 kullanılmalıdır].

[YAPILACAK: Paragraf 2, yazarlar tarafından: Şekil 5 ve Tablo S8 içindeki garantinin maliyetini, Tablo S6 içindeki Attention+penalty ihlalleriyle ilişkilendirin. Birincil ölçü olarak ΔJ^{pen} ve stats/tests_T5.csv kullanılmalıdır].

[YAPILACAK: Paragraf 3, yazarlar tarafından: Tablo S6 ve Tablo S7 içindeki E4'ü ve açık sınırına göre eksik enerjiyi tartışın. Her ikisini A5'in kapalı döngü niteliğiyle ilişkilendirin].

[YAPILACAK: Paragraf 4, yazarlar tarafından: yayımlanmış EV2Gym sayılarıyla karşılaştırmayı yalnızca literatür yapılandırması üzerinde (Tablo S14) yapın; farklı simülatörler ya da senaryolar arasında asla karşılaştırma yapmayın].

7.2 Şarj noktası işletmecileri için pratik çıkarımlar

Bu alt bölüm, deneylerden sonra yazarlar tarafından aşağıdaki noktaları kapsayacak şekilde yazılacaktır.

- [YAPILACAK: Trafo limiti her ham eylem için sağlandığında bir CPO'nun ne kazandığı ve koşullu ayrılış sonucunun hizmet taahhüdü açısından ne anlama geldiği.]
- [YAPILACAK: Tablo S8 üzerinden, belirli bir boyuttaki istasyon için hizmet verilen EV başına avro cinsinden garantinin maliyeti.]
- [YAPILACAK: Tablo S10 üzerinden, sürücülerin ayrılış zamanlarını bildirmediği durumlarda konformal varyantın kullanımı ve kabul edilebilir kapsama düzeyleri.]
- [YAPILACAK: Tablo S11 üzerinden, 15 dakikalık kontrol adımına göre kontrol adımı başına çıkarım süresi.]

7.3 Sınırlılıklar

Teorem 1 kapsamındaki ayrılış sonucu, bildirilen ayrılış zamanlarına ve gereksinimlere (A2) dayanmaktadır. Konformal genişletmemiz yalnızca ayrılış adımını gevşetmekte, kapsaması marjinal kalmakta ve son tarihlerin stratejik olarak yanlış bildirilmesi [60] modelin dışında kalmaktadır. Bölüm 4.4 içindeki iki EV'li örneğin gösterdiği gibi toplam olurluluk (A5) kapalı döngüde sağlanamayabilir. Bu tür adımlarda ayrılış gereksinimi yalnızca Teorem 1(b) kapsamındaki EV'ler için garanti edilir; Lemma S5 ise kalan eksik enerjiyi ortadan kaldırmadan sınırlar. Gelecek boyunca ortak olurluluğu sertifikalayan bir katman, zamana bağlı kısıtlara ihtiyaç duyacak ve tek toplamlı izdüşüm yapısını kaybedecektir.

Trafoya ilişkin sonuç, A3 tek adım modelini ve A6'daki dışsal kapasite payını gerektirir; denetleyici A6'yı uygulamaz. Lemma S7, kullandığımız EV2Gym ayarları için A3'ü ispatlamaktadır; buna karşın gerçek bir batarya yönetim sistemi komut edilenden daha az güç çekebilir. Eksik teslimat, bir EV'nin enerjisini sınırların varsaydığı değerin altına düşürür; bu nedenle donanım uygulamasında eşikler üzerinde bir pay ya da ölçülen enerjiden geri besleme gerekecektir; bu çözüm burada analiz edilmemiştir. A1, EV2Gym'in üstel şarj gücü azalması için geçerlidir; ancak çok daha dik bir azalma bu varsayımı bozacaktır. Model, gerilim limitleri ya da hat akışları olmaksızın tek bir trafonun arkasındaki tek bir istasyonu kapsar ve ek bağlantılı toplam kısıtları Önerme 1 kapsamının dışında kalacaktır.

Deneylerde EV2Gym'in kayıpsız muhasebesi kullanılmakta ve deşarj fiyatı şarj fiyatına eşit alınmaktadır. Dolayısıyla V2G arbitrajı ne gidiş-dönüş kaybı ne de yıpranma maliyeti içerir; bu nedenle deşarjdan elde edilen kârlar iyimser olabilir ve duyarlılık çalışmaları bu etkiyi yalnızca tek bir istasyon boyutunda incelemektedir. Tüm sonuçlar, EV2Gym istatistiklerinden üretilen sentetik varışlar ve Hollanda gün öncesi fiyatlarıyla yapılan simülasyonlardan elde edilmiştir; bazı geç akşam oturumları epizot ufkuna sığmamakta ve tahmin gürültüsü sentetiktir. Şebeke büyüklükleri N ile doğrusal olarak ölçeklendiğinden test

istasyonlarının şarj ünitesi başına istatistikleri eğitimdekilerle örtüşmekte; bunları yalnızca stres düzeyi değiştirmektedir.

Bazı karşılaştırmalar tam olarak eşdeğer koşullarda yapılmamıştır. EV-GNN, kendi algoritması ve ödülüyle, tek bir boyutta, her profil için ayrı olarak, çalıştırma başına tek bir yük ve PV çekilişiyle ve varsayılanından daha az adımla eğitilmektedir. eMPC-HiGHS yeniden gerçeklememiz ufku içindeki kesin fiyatları ve varışları bilmekte, MLP yalnızca $N \leq 20$ için raporlanmakta ve GNN-DT çalıştırılmamıştır. Optimumlar, tek adımlık bir geçiş bandı ve %1'lik bir pay dışında kesin olan dış şarj gücü azalması satırlarını yuvarlama payıyla birlikte kullanmaktadır. Ayrıca optimumlar çevrim içi bir denetleyicinin bilgi kısıtlarını göz ardı etmektedir; dolayısıyla her açığın bir kısmı geleceği bilmemenin bedelidir.

8 Sonuç

Bu makale, bir CPO istasyonunda V2G şarj kontrolü için boyuttan bağımsız bir dikkat tabanlı politikayı olurluluğu koruyan bir güvenlik katmanıyla birleştirmiştir. Katman, eğitim ve kullanım sırasında ham eylemleri şarj gücü azalmasını dikkate alan araç başına sınırlara ve iki yönlü trafo limitine $O(N \log N)$ sürede izdüşürmektedir. Teorem 1 iki katmanlı bir sonuç vermektedir. Tek adım modeli ve şebeke kapasite payı koşulu altında trafo limiti, her ham eylem dizisi için her adımda sağlanır. Kalış süresi boyunca olursuz adımla karşılaşmayan her EV kabul edilen ayrılış gereksinimini karşılar; diğerlerinin eksik enerjisini ise bir açık sınırı sınırlar.

Sıfır-atış değerlendirmede [SONUÇ: $N = 200$'e kadar cezalı kâr açığına ilişkin bir veya iki cümle, Tablo S5]. Kısıtların sağlanması açısından [SONUÇ: aşırı yük enerjisi, eksik enerji ve E4 hakkında bir cümle, Tablo S6 ve S7]. Garantinin maliyeti [SONUÇ: hizmet verilen EV başına ΔJ^{pen} ve Δ kâr hakkında bir cümle, Tablo S8] olarak bulunmuştur.

Bir CPO açısından üç sınırlılık en çok önem taşımaktadır. Birincisi, ayrılış sonucu bildirilmiş gereksinimler ve ayrılış zamanları ya da yalnızca marjinal kapsamaya sahip kalibre edilmiş bir ayrılış sınırı gerektirir. İkincisi, trafoya ilişkin sonuç her EV'nin komut edilen gücü çektiğini varsayar; gerçek batarya yönetim sistemleri ise daha az güç çekebilir. Üçüncüsü, ekonomik değerlendirme gidiş-dönüş kayıplarını ve batarya yıpranmasını dışarıda bırakmaktadır. Gelecekteki çalışmalar sınırlara ölçülen enerjiden geri besleme ekleyebilir, olurlu kümeyi birden fazla trafoyu ve doğrusallaştırılmış gerilim limitlerini kapsayacak şekilde genişletebilir ve gelecek boyunca ortak olurluluğu sertifikalayabilir. Kaydedilmiş şarj oturumlarıyla yapılacak testler, model ile uygulama arasında kalan farkı daraltabilecektir.

Makale Bilgi Formu

Yazarların Katkıları
[YAPILACAK: Her yazarın katkısını belirtin; örneğin "Yazar 1: kavramsallaştırma, yöntem, yazılım, yazım; Yazar 2: danışmanlık, gözden geçirme ve düzenleme"; yenilenen DergiPark sistemi ayrıca bir katkı rolü beyanı da isteyebilir].

Teşekkür
[YAPILACAK: Yazarlık ölçütlerini karşılamayan katkı sahiplerine teşekkür edin ya da "Uygulanamaz" yazın]. [YAPILACAK: Teşekkür (ya da Yöntem) bölümü için yapay zekâ kullanımına ilişkin cümle, yazarlar tarafından yazılacaktır; SAUCIS bu beyanın Yapay Zekâ Beyanı'nın yanı sıra Yöntem ya da Teşekkür bölümünde de yapılmasını şart koşmaktadır].

Çıkar Çatışması
Yazarlar, bu makalenin yayımlanmasıyla ilgili herhangi bir çıkar çatışması bulunmadığını beyan eder. [YAPILACAK: Bu beyanı onaylayın].

Destek/Destekleyen Kuruluşlar
[YAPILACAK: Her mali destek kaynağını proje numaralarıyla belirtin ya da herhangi bir mali destek alınmadığını ifade edin].

Etik Onay
[YAPILACAK: Aşağıdaki ifadeyi onaylayın]. Bu çalışma; insan katılımcı, yazarlarca toplanmış insan verisi ya da hayvan içermeyen bir simülasyon çalışması olduğundan etik kurul onayı gerekmemiştir. Yazarlar,

araştırma ve yayın etiğine uyduklarını beyan eder.

Erişilebilirlik
Kod, senaryo yapılandırmaları, test tekrarları ve analiz betikleri herkese açık bir depoda yayımlanacaktır. [YAPILACAK: Depo bağlantısı, lisans ve arşivlenmiş sürüm]. Deneylerde `55ef368c` commit'indeki açık EV2Gym kodu ve karşılaştırma yöntemlerinden biri için `01aa1b7a` commit'indeki açık EV-GNN kodu kullanılmaktadır.

Yapay Zekâ Beyanı
[YAPILACAK: Yazarlar tarafından yazılacaktır. Yapay zekâ katkılarının olgusal bir kaydı `review/ai_contribution_record.md` dosyasında tutulmaktadır].

İntihal Beyanı
Bu makale iThenticate™ ile taranmıştır.

Terim Sözlüğü

Bu çeviride kullanılan terimler aşağıda listelenmiştir (İngilizce → Türkçe). Matematikte, tablolarda ve şekillerde kullanılan kısaltmalar (RL, EV, CPO, V2G, LLF, PPO vb.) İngilizce biçimleriyle korunmuştur. Karşılaştırılan yöntemlerin etiketleri (Attention+penalty, Attention+PPO-Lagrangian, Deep Sets+safety layer, eMPC-HiGHS vb.) şekil açıklamalarıyla tutarlı olması için İngilizce bırakılmıştır.

İngilizce	Türkçe
actor / critic	aktör / kritik
admission control	kabul kontrolü
admitted requirement	kabul edilen gereksinim
attention policy	dikkat tabanlı politika
baseline	karşılaştırma yöntemi (baseline)
charge point operator (CPO)	şarj noktası işletmecisi (CPO)
charger	şarj ünitesi
charging taper	şarj gücü azalması (taper)
common shift	ortak kaydırma
conformal prediction; split-conformal	konformal tahmin; bölünmüş konformal
cost of the guarantee	garantinin maliyeti
coverage	kapsama
deficit bound	açık sınırı
departure (energy) requirement	ayrılış (enerji) gereksinimi
deployment	kullanım (devreye alma) aşaması
electric vehicle (EV)	elektrikli araç (EV)
endpoint (primary)	(birincil) sonlanım noktası
energy not served	karşılanmayan enerji
episode	epizot (episode)
fallback rule	yedek kural
feasibility; feasible; infeasible step	olurluluk; olurlu; olursuz adım
grid headroom	şebeke kapasite payı
hard / soft (constraint, optimum)	katı / yumuşak (kısıt, optimum)
inflexible load	esnek olmayan yük
Lagrangian	Lagrange
latest-start trajectory	en geç başlangıç yörüngesi
laxity	esneklik payı (laxity)
least-laxity-first (LLF)	en az esneklik payı önce (LLF)
lower / upper bound	alt / üst sınır
mask; key-padding mask	maske; anahtar dolgu maskesi
model predictive control (MPC)	model öngörülü kontrol (MPC)
optimality gap	optimallik açığı
overload (energy)	aşırı yük (enerjisi)
penalised profit	cezalı kâr
penalty	ceza
perfect-information optimum	tam bilgili optimum
policy	politika
projection	izdüşüm (projeksiyon)
raw action; commanded power; realised power	ham eylem; komut edilen güç; gerçekleşen güç
reachable energy	erişilebilir enerji
reinforcement learning (RL)	pekiştirmeli öğrenme (RL)
replay (test replay)	tekrar (test tekrarı, replay)
request pipeline	talep işleme hattı
reward	ödül
rollout	veri toplama turu (rollout)
safety layer	güvenlik katmanı
seed	tohum (seed)
shortfall	eksik enerji (eksiklik)
size-agnostic	boyuttan bağımsız
smoothed LLF (sLLF)	yumuşatılmış LLF (sLLF)
step	adım
stress level	stres düzeyi
token	belirteç (token)
transformer (power)	transformatör (trafo)
transformer encoder (neural)	Transformer kodlayıcı

İngilizce	Türkçe
transformer limit; transformer rating	trafo limiti; trafo anma gücü
vehicle-to-grid (V2G)	araçtan şebekeye (V2G)
zero-shot transfer	sıfır-atış aktarım (yeniden eğitim olmadan)

Kaynaklar

[1] D. Qiu, Y. Wang, W. Hua, and G. Strbac, "Reinforcement learning for electric vehicle applications in power systems: A critical review," *Renewable and Sustainable Energy Reviews*, vol. 173, p. 113052, Mar. 2023.

[2] P. Michailidis, I. Michailidis, and E. Kosmatopoulos, "Reinforcement learning for electric vehicle charging management: Theory and applications," *Energies*, vol. 18, p. 5225, Oct. 2025.

[3] N. Sadeghianpourhamami, J. Deleu, and C. Develder, "Definition and evaluation of model-free coordination of electrical vehicle charging with reinforcement learning," *IEEE Transactions on Smart Grid*, vol. 11, pp. 203–214, Jan. 2020.

[4] Z. Ye, Y. Gao, and N. Yu, "Learning to operate an electric vehicle charging station considering vehicle-grid integration," *IEEE Transactions on Smart Grid*, vol. 13, pp. 3038–3048, July 2022.

[5] C. D. Korkas, C. D. Tsaknakis, A. C. Kapoutsis, and E. Kosmatopoulos, "Distributed and multi-agent reinforcement learning framework for optimal electric vehicle charging scheduling," *Energies*, vol. 17, p. 3694, July 2024.

[6] S. Orfanoudakis, C. Diaz-Londono, Y. Emre Yılmaz, P. Palensky, and P. P. Vergara, "EV2Gym: A flexible V2G simulator for EV smart charging research and benchmarking," *IEEE Transactions on Intelligent Transportation Systems*, vol. 26, pp. 2410–2421, Feb. 2025.

[7] S. Orfanoudakis, N. K. Panda, P. Palensky, and P. P. Vergara, "A graph neural network enhanced decision transformer for efficient optimization in dynamic smart charging environments," *Energy and AI*, vol. 23, p. 100679, Jan. 2026.

[8] D. Tabas and B. Zhang, "Computationally efficient safe reinforcement learning for power systems," in *2022 American Control Conference (ACC)*, pp. 3303–3310, IEEE, June 2022.

[9] E. Altman, *Constrained Markov Decision Processes: Stochastic Modeling*. Routledge, Dec. 2021.

[10] S. Gu, L. Yang, Y. Du, G. Chen, F. Walter, J. Wang, and A. Knoll, "A review of safe reinforcement learning: Methods, theories, and applications," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 46, pp. 11216–11235, Dec. 2024.

[11] S. Orfanoudakis, V. Robu, E. M. Salazar, P. Palensky, and P. P. Vergara, "Scalable reinforcement learning for large-scale coordination of electric vehicles using graph neural networks," *Communications Engineering*, vol. 4, p. 118, July 2025.

[12] X. Wang, N. I. Nimalsiri, Y. Xia, P. Wang, and S. K. Halgamuge, "HetGPS: Scalable graph multi-agent reinforcement learning with physics-anchored adaptive safety for EV charging," 2026. arXiv preprint arXiv:2608.00679.

[13] G. Dalal, K. Dvijotham, M. Vecerík, T. Hester, C. Păduraru, and Y. Tassa, "Safe exploration in continuous action spaces," 2018. arXiv preprint arXiv:1801.08757.

[14] B. Chen, P. L. Donti, K. Baker, J. Z. Kolter, and M. Bergés, "Enforcing policy feasibility constraints through differentiable projection for energy optimization," in *Proceedings of the Twelfth ACM International Conference on Future Energy Systems*, e-Energy '21, pp. 199–210, ACM, June 2021.

[15] G. Wan, P. Zeng, X. Dong, C. Song, S. Cui, D. Li, Q. Dong, Y. Liu, and H. Bai, "Logic-informed reinforcement learning for cross-domain optimization of large-scale cyber-physical systems," 2025. arXiv preprint arXiv:2511.00806.

[16] Y. Guan, J. Zhang, W. Ma, and L. Che, "Rule-based shields embedded safe reinforcement learning approach for electric vehicle charging control," *International Journal of Electrical Power & Energy Systems*, vol. 157, p. 109863, June 2024.

[17] A. Zhang, C. Liu, K. Makantasis, X. Chen, T. Ward, and L. Cheng, "DuMES: Deep reinforcement learning-based EV charging scheduling with dual-layer safety modules," *IET Smart Energy Systems*, vol. 1, pp. 232–246, Nov. 2025.

[18] N. Chen, C. Kurniawan, Y. Nakahira, L. Chen, and S. H. Low, "Smoothed least-laxity-first algorithm for electric vehicle charging: Online decision and performance analysis with resource augmentation," *IEEE Transactions on Smart Grid*, vol. 13, pp. 2209–2217, May 2022.

[19] H. Yan, S. Ding, J. Zhang, X. Yao, Y. Liu, H. Wang, C. Luo, and Y. Shi, "Hierarchical constrained reinforcement learning with dynamic boundary for spatio-temporal vehicle-to-grid scheduling," 2026. arXiv preprint arXiv:2608.03409.

[20] K. C. Kiwiel, "Breakpoint searching algorithms for the continuous quadratic knapsack problem," *Mathematical Programming*, vol. 112, pp. 473–491, Nov. 2007.

[21] B. Wang, L. Lin, and Y.-J. Liu, "Efficient projection onto the intersection of a half-space and a box-like set and its generalized Jacobian," *Optimization*, vol. 71, pp. 1073–1096, July 2022.

[22] H. Li, Z. Wan, and H. He, "Constrained EV charging scheduling based on safe deep reinforcement learning," *IEEE Transactions on Smart Grid*, vol. 11, pp. 2427–2439, May 2020.

[23] G. Song, H. Xie, J. Zhang, H. Fu, Z. Shi, D. Feng, X. Song, and H. Zhang, "Long-term efficient energy management for multi-station collaborative electric vehicle charging: A transformer-based multi-agent reinforcement learning approach," *Applied Energy*, vol. 397, p. 126315, Nov. 2025.

[24] F. Zhang, Q. Yang, and D. An, "Hamlet: Hierarchical multi-objective reinforcement learning method for charging power control of electric vehicles with dynamic quantity," *IEEE Transactions on Smart Grid*, vol. 15, pp. 783–794, Jan. 2024.

[25] J. Caballé, P. Segovia, C. Ocampo-Martinez, and N. Quijano, "Large-scale EV charging coordination: a detailed exploration of mean-field and reinforcement learning approaches," *Control Engineering Practice*, vol. 168, p. 106669, Mar. 2026.

[26] Z. J. Lee, G. Lee, T. Lee, C. Jin, R. Lee, Z. Low, D. Chang, C. Ortega, and S. H. Low, "Adaptive charging networks: A framework for smart electric vehicle charging," *IEEE Transactions on Smart Grid*, vol. 12, pp. 4339–4350, Sept. 2021.

[27] C. Diaz-Londono, S. Orfanoudakis, P. P. Vergara, P. Palensky, F. Ruiz, and G. Gruosso, "Open source algorithms for maximizing V2G flexibility based on model predictive control," *Electric Power Systems Research*, vol. 250, p. 112082, Jan. 2026.

[28] C. Tessler, D. J. Mankowitz, and S. Mannor, "Reward constrained policy optimization," in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2019.

[29] J. Achiam, D. Held, A. Tamar, and P. Abbeel, "Constrained policy optimization," in *Proceedings of the 34th International Conference on Machine Learning (ICML)*, vol. 70 of *Proceedings of Machine Learning Research*, pp. 22–31, PMLR, 2017.

[30] T. Su, T. Wu, J. Zhao, A. Scaglione, and L. Xie, "A review of safe reinforcement learning methods for modern power systems," *Proceedings of the IEEE*, vol. 113, pp. 213–255, Mar. 2025.

[31] J. Fan, A. Liebman, and H. Wang, "Safety-aware reinforcement learning for electric vehicle charging station management in distribution network," in *2024 IEEE Power & Energy Society General Meeting (PESGM)*, pp. 1–5, IEEE, July 2024.

[32] Z. Zhang, R. Rigo-Mariani, N. Hadjsaid, and Y. Xu, "Model-free safe deep reinforcement learning for grid-to-vehicle management considering grid constraints and transformer thermal stress," *Engineering Applications of Artificial Intelligence*, vol. 162, p. 112529, Dec. 2025.

[33] Z. Zhang, R. Rigo-Mariani, N. Hadjsaid, and Y. Xu, "Safe on-policy deep reinforcement learning-based electric vehicle charging management under transformer thermal stress," in *2026 IEEE Power & Energy Society General Meeting (PESGM)*, pp. 1–5, IEEE, July 2026.

[34] R. Eland, S. Orfanoudakis, and P. P. Vergara, "Safe reinforcement learning for V2G-enabled electric vehicle aggregators," in *Machine Learning and Principles and Practice of Knowledge Discovery in Databases (ECML PKDD 2025 Workshops)* (I. Koprinska, J. Mendes-Moreira, and P. Branco, eds.), vol. 2841 of *Communications in Computer and Information Science*, pp. 76–91, Springer Nature Switzerland, 2026.

[35] C. Huang, J. Fan, W. Wang, and H. Wang, "Safe decentralized operation of EV virtual power plant with limited network visibility via multi-agent reinforcement learning," in *2026 IEEE Power & Energy Society General Meeting (PESGM)*, pp. 1–5, IEEE, July 2026.

[36] M. Alshiekh, R. Bloem, R. Ehlers, B. Könighofer, S. Niekum, and U. Topcu, "Safe reinforcement learning via shielding," *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, Apr. 2018.

[37] G. Ceusters, M. A. Putratama, R. Franke, A. Nowé, and M. Messagie, "An adaptive safety layer with hard constraints for safe reinforcement learning in multi-energy management systems," *Sustainable Energy, Grids and Networks*, vol. 36, p. 101202, Dec. 2023.

[38] G. Demirel, S. Grafenhorst, J. Ohm, B. Schäfer, K. Förderer, and V. Hagenmeyer, "Multi-objective reinforcement learning with shielding for control and safety in power grids," *ACM SIGEnergy Energy Informatics Review*, vol. 5, pp. 93–104, Sept. 2025.

[39] M. Zaman and S. Abdelwahed, "Graph-based bi-level reinforcement learning for coordinated EV fast charging under distribution constraints," in *2026 IEEE Transportation Electrification Conference & Expo (ITEC) & Electric Aircraft Technologies Symposium (EATS) (ITEC+EATS)*, pp. 1–6, IEEE, June 2026.

[40] S. Fujimoto, H. van Hoof, and D. Meger, "Addressing function approximation error in actor-critic methods," in *Proceedings of the 35th International Conference on Machine Learning (ICML)*, vol. 80 of *Proceedings of Machine Learning Research*, pp. 1587–1596, PMLR, 2018.

[41] S. Orfanoudakis, B. Elders, P. Palensky, and P. P. Vergara, "Can A.I. revolutionize EV dispatch?," in *Machine Learning and Principles and Practice of Knowledge Discovery in Databases (ECML PKDD 2025 Workshops)* (I. Koprinska, J. Mendes-Moreira, and P. Branco, eds.), vol. 2841 of *Communications in Computer and Information Science*, pp. 11–25, Springer Nature Switzerland, 2026.

[42] B. Amos and J. Z. Kolter, "OptNet: Differentiable optimization as a layer in neural networks," in *Proceedings of the 34th International Conference on Machine Learning (ICML)*, vol. 70 of *Proceedings of Machine Learning Research*, pp. 136–145, PMLR, 2017.

[43] A. Agrawal, B. Amos, S. T. Barratt, S. Boyd, S. Diamond, and J. Z. Kolter, "Differentiable convex optimization layers," in *Advances in Neural Information Processing Systems*, vol. 32, Curran Associates, Inc., 2019.

[44] M. Li, S. Kolouri, and J. Mohammadi, "Learning to solve optimization problems with hard linear constraints," *IEEE Access*, vol. 11, pp. 59995–60004, 2023.

[45] S. Gros, M. Zanon, and A. Bemporad, "Safe reinforcement learning via projection on a safe set: How to achieve optimality?," *IFAC-PapersOnLine*, vol. 53, no. 2, pp. 8076–8081, 2020.

[46] K. Kasaura, S. Miura, T. Kozuno, R. Yonetani, K. Hoshino, and Y. Hosoe, "Benchmarking actor-critic deep reinforcement learning algorithms for robotics control with action constraints," *IEEE Robotics and Automation Letters*, vol. 8, pp. 4449–4456, Aug. 2023.

[47] H. Markgraf, S. Sawant, H. Krasowski, L. Schäfer, S. Gros, and M. Althoff, "Safe reinforcement learning using action projection: Safeguard the policy or the environment?," 2025. arXiv preprint arXiv:2509.12833.

[48] M. Zaheer, S. Kottur, S. Ravanbakhsh, B. Póczos, R. Salakhutdinov, and A. J. Smola, "Deep sets," in *Advances in Neural Information Processing Systems*, vol. 30, Curran Associates, Inc., 2017.

[49] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, Curran Associates, Inc., 2017.

[50] J. Lee, Y. Lee, J. Kim, A. R. Kosiorek, S. Choi, and Y. W. Teh, "Set transformer: A framework for attention-based permutation-invariant neural networks," in *Proceedings of the 36th International Conference on Machine Learning (ICML)*, vol. 97 of *Proceedings of Machine Learning Research*, pp. 3744–3753, PMLR, 2019.

[51] S. Hu, F. Zhu, X. Chang, and X. Liang, "UPDeT: Universal multi-agent RL via policy decoupling with transformers," in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2021.

[52] C. K. Joshi, Q. Cappart, L.-M. Rousseau, and T. Laurent, "Learning the travelling salesperson problem requires rethinking generalization," *Constraints*, vol. 27, pp. 70–98, Apr. 2022.

[53] Y. Zhang, X. Chen, and Y. Zhang, "Transfer deep reinforcement learning-based large-scale V2G continuous charging coordination with renewable energy sources," 2022. arXiv preprint arXiv:2210.07013.

[54] J. Sales-Ortiz and O. Ardakanian, "Efficient trading of aggregate bidirectional EV charging flexibility with reinforcement learning," in *The 15th ACM International Conference on Future and Sustainable Energy Systems*, e-Energy '24, pp. 134–146, ACM, May 2024.

[55] B. Jin, S. Sun, Y. Zhang, S. Zheng, and H. Yu, "Telemetry-robust safe zero-shot graph multi-agent reinforcement learning for active voltage control across distribution feeders," *Sensors*, vol. 26, p. 5752, Sept. 2026.

[56] B. H. K. Reddy, "Deadline-aware electric vehicles charging with distribution transformer overload mitigation," 2026. arXiv preprint arXiv:2607.00935.

[57] E. van Huffelen, R. Brouwer, and M. van den Akker, "Grid-constrained online scheduling of flexible electric vehicle charging," *Energies*, vol. 18, p. 5063, Sept. 2025.

[58] K. Christensen, B. N. Jørgensen, and Z. G. Ma, "A multi-agent, laxity-based aggregation strategy for cost-effective electric vehicle charging and local transformer overload prevention," *Sustainability*, vol. 17, p. 3847, Apr. 2025.

[59] V. Dyo, "Behavior-neutral smart charging of plugin electric vehicles: Reinforcement learning approach," *IEEE Access*, vol. 10, pp. 64095–64104, 2022.

[60] A. Ferragut, L. Narbondo, and F. Paganini, "Scheduling EV charging with uncertain departure times," *ACM SIGMETRICS Performance Evaluation Review*, vol. 49, pp. 10–15, Mar. 2022.

[61] O. Frendo, N. Gaertner, and H. Stuckenschmidt, "Improving smart charging prioritization by predicting electric vehicle departure time," *IEEE Transactions on Intelligent Transportation Systems*, vol. 22, pp. 6646–6653, Oct. 2021.

[62] G. Gabriele, F. Pavirani, S. S. K. Madahi, and C. Develder, "Forecasting what matters: Decision-focused RL for controlled EV charging with unknown departure times," 2026. arXiv preprint arXiv:2606.19199.

[63] J. Lei, M. G'Sell, A. Rinaldo, R. J. Tibshirani, and L. Wasserman, "Distribution-free predictive inference for regression," *Journal of the American Statistical Association*, vol. 113, pp. 1094–1111, June 2018.

[64] A. N. Angelopoulos and S. Bates, "Conformal prediction: A gentle introduction," *Foundations and Trends® in Machine Learning*, vol. 16, pp. 494–591, Mar. 2023.

[65] L. Lindemann, M. Cleaveland, G. Shim, and G. J. Pappas, "Safe planning in dynamic environments using conformal prediction," *IEEE Robotics and Automation Letters*, vol. 8, pp. 5116–5123, Aug. 2023.

[66] Q. Huangfu and J. A. J. Hall, "Parallelizing the dual revised simplex method," *Mathematical Programming Computation*, vol. 10, pp. 119–142, Dec. 2018.

[67] J. L. Ba, J. Kiros, and G. E. Hinton, "Layer normalization," 2016. arXiv preprint arXiv:1607.06450.

[68] R. Xiong, Y. Yang, D. He, K. W. Zheng, S. Zheng, C. Xing, H. Zhang, Y. Lan, L. Wang, and T.-Y. Liu, "On layer normalization in the transformer architecture," in *Proceedings of the 37th International Conference on Machine Learning (ICML)*, vol. 119 of *Proceedings of Machine Learning Research*, pp. 10524–10533, PMLR, 2020.

[69] Y. Romano, E. Patterson, and E. J. Candès, "Conformalized quantile regression," in *Advances in Neural Information Processing Systems*, vol. 32, Curran Associates, Inc., 2019.

[70] H. Papadopoulos, K. Proedrou, V. Vovk, and A. Gammerman, "Inductive confidence machines for regression," in *Machine Learning: ECML 2002*, pp. 345–356, Springer Berlin Heidelberg, 2002.

[71] V. Vovk, A. Gammerman, and G. Shafer, *Algorithmic Learning in a Random World*. Springer International Publishing, 2022.

[72] J. D. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, "Proximal policy optimization algorithms," 2017. arXiv preprint arXiv:1707.06347.

[73] J. Schulman, P. Moritz, S. Levine, M. I. Jordan, and P. Abbeel, "High-dimensional continuous control using generalized advantage estimation," in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2016.

[74] F. Wilcoxon, "Individual comparisons by ranking methods," *Biometrics Bulletin*, vol. 1, p. 80, Dec. 1945.

[75] R. Agarwal, M. Schwarzer, P. S. Castro, A. C. Courville, and M. G. Bellemare, "Deep reinforcement learning at the edge of the statistical precipice," in *Advances in Neural Information Processing Systems*, vol. 34, pp. 29304–29320, Curran Associates, Inc., 2021.

[76] P. Henderson, R. Islam, P. Bachman, J. Pineau, D. Precup, and D. Meger, "Deep reinforcement learning that matters," *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, Apr. 2018.

[77] A. Paszke, S. Gross, F. Massa, A. K. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. E. Gimelshein, L. Antiga, A. Desmaison, A. Köpf, E. Z. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy, B. Steiner, L. Fang, J. Bai, and S. Chintala, "PyTorch: An imperative style, high-performance deep learning library," in *Advances in Neural Information Processing Systems*, vol. 32, Curran Associates, Inc., 2019.

[78] S. Huang, R. F. J. Dossa, C. Ye, J. Braga, D. Chakraborty, K. Mehta, and J. G. M. Araújo, "CleanRL: High-quality single-file implementations of deep reinforcement learning algorithms," *Journal of Machine Learning Research*, vol. 23, no. 274, pp. 1–18, 2022.

[79] D. P. Kingma and J. L. Ba, "Adam: A method for stochastic optimization," in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2015.